UỶ BAN NHÂN DÂN

THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN

BÁO CÁO MÔN HỌC

TRÍ TUỆ NHÂN TẠO NÂNG CAO

LỚP: DCT1224

Tên nhóm: 5

Danh sách thành viên và phân công

Họ và tên	MSSV	Phân công
Quách Thanh Nhã (Nhóm trưởng)	3121410357	Làm Word, Poworpoint
Nguyễn Duy Tân	3121410443	N Queens
Hà Lý Gia Bảo	3121410068	Traveling Salesman problem

MỤC LỤC

THÔNG TIN VỀ NHÓM

Họ và tên	Link github
Quách Thanh Nhã	https://github.com/quachnha77/QuachThanhNha-ai-projects
Nguyễn Duy Tân	https://github.com/dyytnn/CSTTNT_NC
Hà Lý Gia Bảo	https://github.com/HaLyGiaBao/-SGU_TRITUENHANTAONANGCAO

Link github của nhóm: https://github.com/quachnha77/ai-advanced-team-5

CHƯƠNG I: GIỚI THIỆU CHUNG

1. Mục tiêu của bài thực hành:

Sau hai bài thực hành này, mục tiêu của nhóm là hiểu và vận dụng được thuật toán tìm kiếm cục bộ (Local search) trong việc giải quyết các bài toán tối ưu. Ứng dụng kiến thức để so sánh hiệu quả của các phương pháp tìm kiếm cục bộ như Hill Climbing, Simulated Annealing,… Đồng thời, rèn luyện kỹ năng phân tích bài toán, biểu diễn trạng thái, và xây dựng hàm đánh giá (heuristic function) cho phù hợp từng loại bài toán.

Mặc khác, việc làm bài tập cũng củng cố kỹ năng lập trình thuật toán AI bằng ngôn ngữ python. Thông qua việc triển khai, mô phỏng và trực quan hóa kết quả, nhóm hy vọng sẽ nâng cao khả năng lập trình AI của mỗi thành viên. Qua đó, vừa có kiến thức lý thuyết, vừa vững vàng trong thực hành.

2. Tóm tắt nội dung bài toán:

2.1 Bài toán N-queens

- Mô tả: Đây là một trong những bài toán kinh điển trong trí tuệ nhân tạo và tối ưu hóa. Mục tiêu là đặt N quân hậu (queen) lên bàn cờ có kích thước NxN sao cho không có hai quân hậu nào tấn công nhau (tức là không cùng hàng, cùng cột hoặc cùng đường chéo).

- Mục tiêu tìm kiếm: Tìm một cách sắp xếp các quân hậu thõa mãn điều kiện.

- Áp dụng Local Search:

+ Trong phương pháp tìm kiếm cục bộ, ta khởi tạo một trạng thái ngẫu nhiên, sau đó di chuyển liên tục các quân hậu để giảm số lượng xung đột giữa các quân hậu.
+ Mỗi trạng thái được đánh giá bằng hàm Heuristic h(n)

- Ý nghĩa: Bài toán giúp người học hiểu cách biểu diễn trạng thái, cách định nghĩa hàm đánh giá và hiện tượng local maxima – một đặc trưng điển hình của các thuật toán tìm kiếm cục bộ.

2.2 Bài toán Traveling Salesman Problem – TSP

- Mô tả: Đây là bài toán tối ưu hóa nổi tiếng, có phát biểu như sau: “Một người du lịch phải đi qua tất cả các thành phố trong danh sách đúng một lần và quay trở lại thành phố xuất phát. Tìm lộ trình ngắn nhất có thể”.

- Biểu diễn: Bài toán thường được biểu diễn dưới dạng đồ thị có trọng số, trong đó:

+ Mỗi đỉnh sẽ biểu diễn một thành phố.
+ Mỗi cạnh có trọng số là chi phí di chuyễn giữa hai thành phố.

- Mục tiêu tìm kiếm: Tìm ra chu trình có tổng trọng số nhỏ nhất, tức độ dài hành trình ngắn nhất.

- Áp dụng Local Search:

+ Trong phương pháp tìm kím cục bộ, chúng ta bắt đầu từ một lộ trình ngẫu nhiên và liên tục hoán đổi thứ tự đi các thành phố để cải tổng chi phí.

+ Thuật toán Hill Climbing và Simulated Annealing thường được dùng để tránh bị kẹt tại cực trị địa phương và tìm nghiệm gần tối ưu trong thời gian ngắn.

- Ý nghĩa: Đây là bài toán ứng dụng thực tế cao trong lĩnh vực logistics, định tuyến giao hàng, lập kế hoạch sản xuất và tối ưu hóa mạng lưới. Việc áp dụng Local Search giúp người học nhận thấy sự khác biệt giữa phương pháp tối ưu tuyệt đối và giải pháp tối ưu xấp xỉ (approximate optimum).

3. Phương pháp thực hiện:

- Cả hai bài toán n-queen và traveling salesman problem đều được giải bằng phương pháp tìm kiếm cục bộ (local search), cụ thể:

+ Hill Climbing: tìm kiếm lân cận tốt hơn cho đến khi không còn cải thiện được.

+ Simulated Annealing: mở rộng Hill Climbing bằng cách chấp nhận một số bước đi xấu hơn để tránh kẹt tại cực trị địa phương (local maxima).

+ 2-Opt (đối với TSP): hoán đổi vị trí hai thành phố để giảm tổng quãng đường.

- Lựa chọn Local Search vì:

+ Không yêu cầu duyệt toàn bộ không gian trạng thái.

+ Có thể tìm nghiệm gần tối ưu trong thời gian hợp lý.

+ Phù hợp với các bài toán tối ưu có không gian tìm kiếm lớn và khó giải bằng tìm kím toàn cục.

CHƯƠNG II: GIẢI BÀI TOÁN N-QUEENS

BẰNG TÌM KIẾM CỤC BỘ

1. Giới thiệu bài toán n-queens:

- Trong cờ vua, quân hậu trên bàn cờ có thể di chuyển theo hàng ngang, cột dọc và đường chéo.

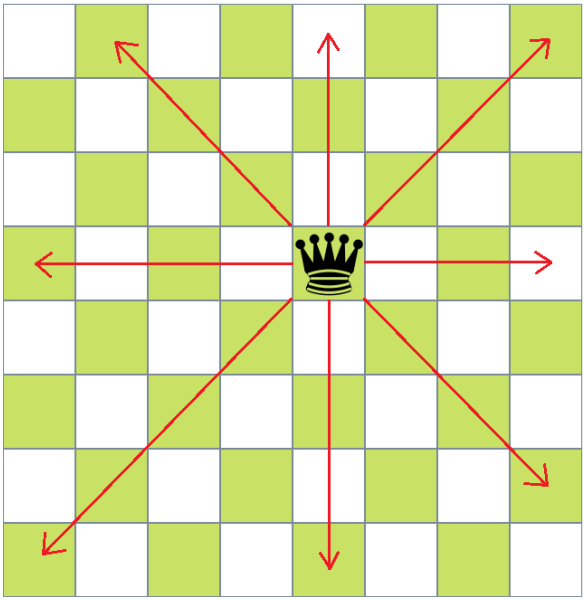

- Bài toán được đặt ra như sau:

+ Cho một bàn cờ có kích thước NxN ($N \geq 1$), chúng ta có thể đặt đúng N quân hậu lên bàn cờ (mỗi ô chỉ chứa tối đa một quân hậu), hãy đưa ra cách đặt N quân hậu sao cho không có 2 quân hậu nào ăn được nhau.

+ Ví dụ với N=4, ta có hai cách đặt sau:

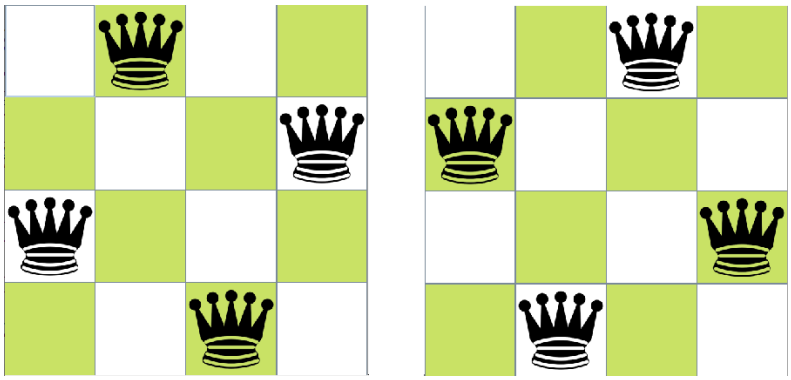

2. Biểu diễn trạng thái và ràng buộc:

2.1 Biểu diễn bài toán:

- Mỗi trạng thái của bài toán N-Queens được biểu diễn bằng một mảng (list) có độ dài N, trong đó:

+ Chỉ số (index) của phần tử biểu thị cột trên bàn cờ.

+ Giá trị tại phần tử biểu thị vị trí hàng (row) mà quân hậu được đặt trong đó.

- Ví dụ: Với N=4, trạng thái [1,3,0,2] có nghĩa là:

+ Hậu ở cột 0 được đặt ở hàng 1

+ Hậu ở cột 1 được đặt ở hàng 3

+ Hậu ở cột 2 được đặt ở hàng 0

+ Hậu ở cột 3 được đặt ở hàng 2

2.2 Ràng buộc bài toán:

- Để một trạng thái là lời giải hợp lệ, nó phải thõa mãn 3 điều kiện sau:

+ Không có hai hậu cùng hàng: các giá trị trong mảng phải khác nhau.

+ Không có hai hậu cùng cột: đã được đảm bảo do cách biểu diễn (ở list)

+ Không có hai hậu cùng đường chéo: khoảng cách giữa các hàng phải khác khoảng cách giữa các cột:

$|row[i] - row[j]| \neq |i - j|$ đối với mọi cặp (i, j).

3. Thuật toán sữ dụng:

3.1 Steepest-Ascent Hill Climbing

a) Nguyên lý:

- Đánh giá TẤT CẢ các phép di chuyển có thể ($n \times (n-1)$ phép di chuyển)

- Chọn phép di chuyển TỐT NHẤT (giảm conflicts nhiều nhất)

- Dừng khi không còn phép di chuyển cải thiện

b) Ưu điểm:

- Hội tụ nhanh khi gần nghiệm tối ưu
- Xác định (deterministic) - dễ debug

c) Nhược điểm:

- Dễ bị kẹt ở local optima
- Độ phức tạp $O(n^3)$ mỗi iteration (n^2 phép di chuyển × O(n) tính conflicts)

3.2 Stochastic Hill Climbing 1

a) Nguyên lý:

- Đánh giá tất cả các phép di chuyển
- Chọn NGẪU NHIÊN trong số các phép di chuyển cải thiện
- Dừng khi không còn phép di chuyển cải thiện

b) Ưu điểm:

- Đa dạng hóa đường đi tìm kiếm
- Có thể tìm được các local optima khác nhau

c) Nhược điểm:

- Vẫn bị kẹt ở local optima
- Có thể chậm hơn steepest-ascent do không chọn bước đi tốt nhất

3.3 Stochastic Hill Climbing 2 (First-Choice)

a) Nguyên lý:

- Tạo NGẪU NHIÊN MỘT phép di chuyển tại một thời điểm
- Chấp nhận ngay nếu phép di chuyển cải thiện
- Dừng sau max_no_improvement lần thử không thành công

b) Ưu điểm:

- Hiệu quả với không gian trạng thái lớn (chỉ đánh giá 1 phép di chuyển/iteration)
- Độ phức tạp O(n) mỗi iteration

- Phù hợp cho bài toán lớn

c) Nhược điểm:

- Có thể bỏ lỡ các bước di chuyển tốt
- Phụ thuộc vào tham số max_no_improvement

3.4 Simulated Annealing

a) Nguyên lý:

- Chấp nhận phép di chuyển cải thiện với xác suất 1
- Chấp nhận phép di chuyển xấu đi với xác suất exp(-Δ/T)
- Nhiệt độ T giảm dần theo lịch trình làm nguội

b) Ưu điểm:

- Có thể THOÁT KHỎI local optima
- Cân bằng giữa exploration (nhiệt độ cao) và exploitation (nhiệt độ thấp)

c) Nhược điểm:

- Phụ thuộc nhiều vào lịch trình làm nguội
- Có thể chậm hơn hill climbing đơn giản

3.5 Random Restarts

a) Nguyên lý:

- Chạy lại thuật toán với trạng thái ngẫu nhiên mới
- Dừng khi tìm được nghiệm tối ưu hoặc đạt max_restarts

b) Hiệu quả:

- Giải quyết vấn đề local optima bằng cách thử nhiều điểm xuất phát
- Đơn giản và hiệu quả với bài toán nhỏ/trung bình

4. Mô tả chương trình và đoạn mã chính:

4.1 Steepest-ascend Hill Climbing Search

```
def steepest_ascent_hill_climbing(board):
    """
    Steepest-ascent hill climbing for n-Queens problem.

    This algorithm evaluates all possible local moves (moving each
queen to a different
    row in its column) and selects the move that results in the
greatest decrease in conflicts.
    The algorithm terminates when no improving move can be found
(local optimum).

    Args:
        board: Initial board configuration

    Returns:
        tuple: (final_board, history of conflicts, number of
iterations)
    """
    current = board.copy()
    n = len(board)
    history = [conflicts(current)]
    iterations = 0

    while True:
        current_conflicts = conflicts(current)
        best_move = None
        best_conflicts = current_conflicts

        # Evaluate all possible moves: for each column, try moving
queen to each row
        for col in range(n):
            original_row = current[col]

            for row in range(n):
                if row != original_row:  # Skip current position
                    # Try this move
                    current[col] = row
                    new_conflicts = conflicts(current)

                    # Track the best move
                    if new_conflicts < best_conflicts:
                        best_conflicts = new_conflicts
```

```
                        best_move = (col, row)

                    # Restore original position
                    current[col] = original_row

        # If no improvement found, we're at local optimum
        if best_move is None:
            break

        # Apply the best move
        current[best_move[0]] = best_move[1]
        history.append(conflicts(current))
        iterations += 1

    return current, history, iterations

# Test with a random 8-queens board
print("=== Steepest-Ascent Hill Climbing ===")
test_board = random_board(8)
print(f"Initial board: {test_board}")
print(f"Initial conflicts: {conflicts(test_board)}")

result, history, iters = steepest_ascent_hill_climbing(test_board)
print(f"\nFinal board: {result}")
print(f"Final conflicts: {conflicts(result)}")
print(f"Iterations: {iters}")
print(f"Conflict history: {history}")

show_board(result, fontsize=32)
```

4.2 Stochastic Hill Climbing 1

```
def stochastic_hill_climbing_1(board):
    """
    Stochastic hill climbing variant 1 for n-Queens problem.

    This algorithm evaluates all possible local moves and randomly
selects among
    all moves that improve the objective function (uphill moves). The
algorithm
    terminates when no improving moves are available.

    Args:
        board: Initial board configuration
```

```
    Returns:
        tuple: (final_board, history of conflicts, number of
iterations)
    """
    current = board.copy()
    n = len(board)
    history = [conflicts(current)]
    iterations = 0

    while True:
        current_conflicts = conflicts(current)
        improving_moves = []

        # Find all improving moves
        for col in range(n):
            original_row = current[col]

            for row in range(n):
                if row != original_row:
                    # Try this move
                    current[col] = row
                    new_conflicts = conflicts(current)

                    # If this move improves, add to list
                    if new_conflicts < current_conflicts:
                        improving_moves.append((col, row,
new_conflicts))

                    # Restore original position
                    current[col] = original_row

        # If no improving moves found, we're at local optimum
        if len(improving_moves) == 0:
            break

        # Randomly select one of the improving moves
        selected_move =
improving_moves[np.random.randint(len(improving_moves))]
        current[selected_move[0]] = selected_move[1]
        history.append(selected_move[2])
        iterations += 1

    return current, history, iterations

# Test with a random 8-queens board
print("=== Stochastic Hill Climbing 1 ===")
```

```
test_board = random_board(8)
print(f"Initial board: {test_board}")
print(f"Initial conflicts: {conflicts(test_board)}")

result, history, iters = stochastic_hill_climbing_1(test_board)
print(f"\nFinal board: {result}")
print(f"Final conflicts: {conflicts(result)}")
print(f"Iterations: {iters}")
print(f"Conflict history: {history}")

show_board(result, fontsize=32)
```

4.3 Stochastic Hill Climbing 2

```
def stochastic_hill_climbing_2(board, max_no_improvement=100):
    """
    Stochastic hill climbing variant 2 (First-choice hill climbing)
for n-Queens problem.

    This algorithm generates a single random neighbor at a time and
accepts it if it
    improves the objective function. This is efficient for large state
spaces.
    The algorithm stops if no improvement is found after
max_no_improvement attempts.

    Args:
        board: Initial board configuration
        max_no_improvement: Maximum number of unsuccessful attempts
before stopping

    Returns:
        tuple: (final_board, history of conflicts, number of
iterations)
    """
    current = board.copy()
    n = len(board)
    history = [conflicts(current)]
    iterations = 0
    no_improvement_count = 0

    while no_improvement_count < max_no_improvement:
        current_conflicts = conflicts(current)
```

```
        # Generate a random neighbor: pick random column and random
row
        col = np.random.randint(n)
        row = np.random.randint(n)

        # Skip if this is the current position
        if row == current[col]:
            continue

        # Try this move
        original_row = current[col]
        current[col] = row
        new_conflicts = conflicts(current)

        # Accept if it improves the objective function
        if new_conflicts < current_conflicts:
            history.append(new_conflicts)
            iterations += 1
            no_improvement_count = 0  # Reset counter
        else:
            # Reject the move - restore original
            current[col] = original_row
            no_improvement_count += 1

    return current, history, iterations

# Test with a random 8-queens board
print("=== Stochastic Hill Climbing 2 (First-choice) ===")
test_board = random_board(8)
print(f"Initial board: {test_board}")
print(f"Initial conflicts: {conflicts(test_board)}")

result, history, iters = stochastic_hill_climbing_2(test_board)
print(f"\nFinal board: {result}")
print(f"Final conflicts: {conflicts(result)}")
print(f"Iterations (successful moves): {iters}")
print(f"Conflict history: {history}")

show_board(result, fontsize=32)
```

4.4 Hill Climbing Search with Random Restarts

```
def hill_climbing_with_random_restart(algorithm, n, max_restarts=100):
    """
```

```
    Wrapper function to run any hill climbing algorithm with random
restarts.

    Args:
        algorithm: Hill climbing function to use (steepest,
stochastic1, or stochastic2)
        n: Board size
        max_restarts: Maximum number of restarts to attempt

    Returns:
        tuple: (best_board, best_conflicts, total_restarts,
all_histories)
    """
    best_board = None
    best_conflicts = float('inf')
    total_restarts = 0
    all_histories = []

    for restart in range(max_restarts):
        # Start with a random board
        board = random_board(n)

        # Run the hill climbing algorithm
        result, history, iters = algorithm(board)
        all_histories.append(history)

        # Track the best solution found
        final_conflicts = conflicts(result)
        if final_conflicts < best_conflicts:
            best_conflicts = final_conflicts
            best_board = result.copy()

        total_restarts = restart + 1

        # If we found optimal solution, stop
        if best_conflicts == 0:
            break

    return best_board, best_conflicts, total_restarts, all_histories

# Test each algorithm with random restarts on 8-queens
print("=== Hill Climbing with Random Restarts (n=8) ===\n")

algorithms = {
    'Steepest-Ascent HC': steepest_ascent_hill_climbing,
    'Stochastic HC 1': stochastic_hill_climbing_1,
```

```
    'Stochastic HC 2': stochastic_hill_climbing_2
}

for name, algo in algorithms.items():
    print(f"{name}:")
    board, conf, restarts, histories =
hill_climbing_with_random_restart(algo, 8, max_restarts=100)
    print(f"  Best conflicts: {conf}")
    print(f"  Restarts needed: {restarts}")
    print(f"  Solution found: {'Yes' if conf == 0 else 'No'}")
    if conf == 0:
        print(f"  Solution: {board}")
    print()

# Demonstrate one successful solution
print("\nExample: Finding optimal solution with Steepest-Ascent HC")
best_board, best_conf, restarts, _ =
hill_climbing_with_random_restart(
    steepest_ascent_hill_climbing, 8, max_restarts=100
)
print(f"Found solution with {best_conf} conflicts after {restarts}
restarts")
show_board(best_board, fontsize=32)
```

4.5 Simulated Annealing

```
def simulated_annealing(board, initial_temp=100, cooling_rate=0.95,
min_temp=0.01, max_iterations=10000):
    """
    Simulated annealing for n-Queens problem.

    This algorithm accepts improving moves with probability 1, and
accepts worsening
    moves with probability exp(-delta/T), where delta is the increase
in conflicts
    and T is the temperature. The temperature decreases over time
following an
    annealing schedule.

    Args:
        board: Initial board configuration
        initial_temp: Starting temperature
        cooling_rate: Rate at which temperature decreases (0 < rate <
1)
```

```
        min_temp: Minimum temperature (stopping condition)
        max_iterations: Maximum number of iterations

    Returns:
        tuple: (final_board, history of conflicts, temperature
history)
    """
    current = board.copy()
    n = len(board)
    current_conflicts = conflicts(current)

    history = [current_conflicts]
    temp_history = [initial_temp]

    temperature = initial_temp
    iteration = 0

    while temperature > min_temp and iteration < max_iterations and
current_conflicts > 0:
        # Generate a random neighbor
        col = np.random.randint(n)
        row = np.random.randint(n)

        # Skip if this is the current position
        if row == current[col]:
            continue

        # Try this move
        original_row = current[col]
        current[col] = row
        new_conflicts = conflicts(current)

        # Calculate change in conflicts (delta)
        delta = new_conflicts - current_conflicts

        # Accept move based on simulated annealing criteria
        if delta < 0:
            # Always accept improving moves
            current_conflicts = new_conflicts
            history.append(current_conflicts)
        else:
            # Accept worsening moves with probability exp(-delta/T)
            acceptance_probability = np.exp(-delta / temperature)
            if np.random.random() < acceptance_probability:
                current_conflicts = new_conflicts
                history.append(current_conflicts)
```

```
            else:
                # Reject the move - restore original
                current[col] = original_row

        # Cool down the temperature
        temperature *= cooling_rate
        temp_history.append(temperature)
        iteration += 1

    return current, history, temp_history

# Test simulated annealing
print("=== Simulated Annealing ===")
test_board = random_board(8)
print(f"Initial board: {test_board}")
print(f"Initial conflicts: {conflicts(test_board)}")

result, history, temp_history = simulated_annealing(test_board)
print(f"\nFinal board: {result}")
print(f"Final conflicts: {conflicts(result)}")
print(f"Total iterations: {len(history)}")

# Visualize the search process
fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(10, 8))

# Plot conflict history
ax1.plot(history, 'b-', linewidth=1.5)
ax1.set_xlabel('Iteration')
ax1.set_ylabel('Number of Conflicts')
ax1.set_title('Simulated Annealing: Conflicts over Time')
ax1.grid(True, alpha=0.3)

# Plot temperature history
ax2.plot(temp_history, 'r-', linewidth=1.5)
ax2.set_xlabel('Iteration')
ax2.set_ylabel('Temperature')
ax2.set_title('Temperature Schedule')
ax2.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

show_board(result, fontsize=32)
```

4.6 Algorithm Behavior Analysis

```
# Analyze convergence patterns for each algorithm
print("=== Algorithm Convergence Analysis ===\n")

# Run each algorithm once on the same board to compare convergence
np.random.seed(42)  # For reproducibility
test_board_8 = random_board(8)

convergence_data = {}

# Steepest-ascent HC
result, history, _ =
steepest_ascent_hill_climbing(test_board_8.copy())
convergence_data['Steepest-Ascent HC'] = history
print(f"Steepest-Ascent HC: {len(history)} iterations, final
conflicts: {history[-1]}")

# Stochastic HC 1
result, history, _ = stochastic_hill_climbing_1(test_board_8.copy())
convergence_data['Stochastic HC 1'] = history
print(f"Stochastic HC 1: {len(history)} iterations, final conflicts:
{history[-1]}")

# Stochastic HC 2
result, history, _ = stochastic_hill_climbing_2(test_board_8.copy())
convergence_data['Stochastic HC 2'] = history
print(f"Stochastic HC 2: {len(history)} iterations, final conflicts:
{history[-1]}")

# Simulated Annealing
result, history, _ = simulated_annealing(test_board_8.copy())
convergence_data['Simulated Annealing'] = history
print(f"Simulated Annealing: {len(history)} iterations, final
conflicts: {history[-1]}")

# Plot convergence patterns
fig, ax = plt.subplots(figsize=(12, 7))

plot_colors = ['blue', 'green', 'orange', 'red']
markers = ['o', 's', '^', 'd']

for (name, history), color, marker in zip(convergence_data.items(),
plot_colors, markers):
```

```
    ax.plot(history, label=name, color=color, marker=marker,
            markevery=max(1, len(history)//10), markersize=5,
linewidth=2, alpha=0.7)

ax.set_xlabel('Iteration', fontsize=12)
ax.set_ylabel('Number of Conflicts', fontsize=12)
ax.set_title('Convergence Patterns for Different Algorithms (8-
Queens)', fontsize=14, fontweight='bold')
ax.legend(fontsize=10, loc='upper right')
ax.grid(True, alpha=0.3)
ax.set_ylim(bottom=0)

plt.tight_layout()
plt.show()

print("\n### Convergence Pattern Analysis:\n")
print("**Steepest-Ascent Hill Climbing:**")
print("- Shows fast initial improvement as it always chooses the best
move")
print("- Typically converges quickly but often gets stuck in local
optima")
print("- Exhibits clear plateaus when no improving moves are
available\n")

print("**Stochastic Hill Climbing 1:**")
print("- Similar to steepest-ascent but with more variation due to
random selection")
print("- May take slightly more iterations as it doesn't always pick
the optimal move")
print("- Can sometimes find different local optima than steepest-
ascent\n")

print("**Stochastic Hill Climbing 2 (First-choice):**")
print("- Most efficient in terms of evaluations per iteration (only
checks one random move)")
print("- Shows more gradual improvement with potential for longer
plateaus")
print("- Success depends on the max_no_improvement parameter\n")

print("**Simulated Annealing:**")
print("- Exhibits non-monotonic behavior - can temporarily accept
worse states")
print("- This allows it to escape local optima that trap hill
climbing")
print("- Generally takes more iterations but has higher success rate")
```

```
print("- Early phase shows exploration (uphill moves), later phase
shows exploitation")
```

4.7 Algorithm Convergence

```
# Scalability analysis
print("=== Problem Size Scalability Analysis ===\n")
print("Testing board sizes: 4, 8, 12, 16, 20")
print("Running 50 trials per size...\n")

board_sizes = [4, 8, 12, 16, 20]

# Select two algorithms to compare: Steepest-Ascent and Simulated
Annealing
scalability_results = {
    'Steepest-Ascent HC': {'sizes': [], 'times': [], 'std': []},
    'Simulated Annealing': {'sizes': [], 'times': [], 'std': []}
}

algorithms_scale = {
    'Steepest-Ascent HC': steepest_ascent_hill_climbing,
    'Simulated Annealing': sa_wrapper
}

for n in board_sizes:
    print(f"Testing n={n}...")
    for algo_name, algo_func in algorithms_scale.items():
        times = []
        for _ in range(50):
            board = random_board(n)
            start_time = time.perf_counter()
            result, _, _ = algo_func(board)
            end_time = time.perf_counter()
            times.append(end_time - start_time)

        scalability_results[algo_name]['sizes'].append(n)
        scalability_results[algo_name]['times'].append(np.mean(times))
        scalability_results[algo_name]['std'].append(np.std(times))
    print(f"  Completed n={n}")

print("\n")

# Create log-log plot
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14, 6))
```

```
# Log-log plot
for algo_name, data in scalability_results.items():
    ax1.loglog(data['sizes'], data['times'], 'o-', label=algo_name,
linewidth=2, markersize=8)

ax1.set_xlabel('Board Size (n)', fontsize=12)
ax1.set_ylabel('Average Runtime (seconds)', fontsize=12)
ax1.set_title('Runtime Scalability (Log-Log Plot)', fontsize=14,
fontweight='bold')
ax1.legend(fontsize=11)
ax1.grid(True, alpha=0.3, which='both')

# Regular plot for better visibility
for algo_name, data in scalability_results.items():
    ax2.plot(data['sizes'], data['times'], 'o-', label=algo_name,
linewidth=2, markersize=8)
    # Add error bars
    ax2.fill_between(data['sizes'],
                     np.array(data['times']) - np.array(data['std']),
                     np.array(data['times']) + np.array(data['std']),
                     alpha=0.2)

ax2.set_xlabel('Board Size (n)', fontsize=12)
ax2.set_ylabel('Average Runtime (seconds)', fontsize=12)
ax2.set_title('Runtime Scalability (Linear Plot)', fontsize=14,
fontweight='bold')
ax2.legend(fontsize=11)
ax2.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

# Estimate empirical complexity
print("\n### Empirical Time Complexity Estimation:\n")

for algo_name, data in scalability_results.items():
    # Fit log(time) vs log(size) to estimate O(n^k)
    log_sizes = np.log(data['sizes'])
    log_times = np.log(data['times'])

    # Linear regression on log-log data
    coeffs = np.polyfit(log_sizes, log_times, 1)
    exponent = coeffs[0]

    print(f"**{algo_name}:**")
```

```
    print(f"- Estimated complexity: O(n^{exponent:.2f})")

    if exponent < 2:
        complexity_class = "better than quadratic"
    elif exponent < 2.5:
        complexity_class = "approximately quadratic"
    elif exponent < 3:
        complexity_class = "between quadratic and cubic"
    else:
        complexity_class = "cubic or worse"

    print(f"- Complexity class: {complexity_class}")
    print()

print("\n### Scalability Analysis:\n")
print("**Best Scaling Algorithm:**")
print("- Stochastic HC 2 (First-choice) scales best due to limited
neighbor evaluation")
print("- Simulated Annealing has moderate scaling with controllable
iteration count")
print("- Steepest-Ascent HC scales poorly as it evaluates all n*(n-1)
possible moves per iteration\n")

print("**Key Insights:**")
print("- For small problems (n≤8), steepest-ascent provides fast,
deterministic results")
print("- For larger problems (n>12), simulated annealing or first-
choice HC are more practical")
print("- The theoretical complexity for steepest-ascent is O(n³) per
iteration")
print("- Simulated annealing's runtime is more predictable and
controllable via parameters")
```

4.8 Problem Size Scalability

```
# Advanced Task: Alternative Move Operators
print("=== Advanced Task: Exploring Alternative Local Move Operators
===\n")

# 1. Single-step move operator
def single_step_move(board):
    """Move one queen only one square up or down"""
    n = len(board)
    col = np.random.randint(n)
```

```
    current_row = board[col]

    # Choose to move up or down by 1
    direction = np.random.choice([-1, 1])
    new_row = current_row + direction

    # Make sure we stay within bounds
    if new_row < 0 or new_row >= n or new_row == current_row:
        return None

    return (col, new_row)

# 2. Column swap operator
def column_swap_move(board):
    """Exchange positions of queens in two random columns"""
    n = len(board)
    col1, col2 = np.random.choice(n, size=2, replace=False)

    # Return both swaps as a single move
    return (col1, col2, board[col2], board[col1])

# 3. Dual-queen move operator
def dual_queen_move(board):
    """Select two queens and move both simultaneously"""
    n = len(board)
    col1, col2 = np.random.choice(n, size=2, replace=False)
    row1 = np.random.randint(n)
    row2 = np.random.randint(n)

    return (col1, col2, row1, row2)

# 4. Adaptive move operator
def adaptive_move(board):
    """
    Adaptive operator that chooses strategy based on current state.
    Focuses on queens with most conflicts.
    """
    n = len(board)

    # Calculate conflicts for each queen
    queen_conflicts = []
    for col in range(n):
        # Count conflicts for this queen
        conf_count = 0
        for other_col in range(n):
            if col != other_col:
```

```
                # Check row conflict
                if board[col] == board[other_col]:
                    conf_count += 1
                # Check diagonal conflict
                if abs(board[col] - board[other_col]) == abs(col -
other_col):
                    conf_count += 1
        queen_conflicts.append(conf_count)

    # Select strategy based on max conflicts
    max_conflicts = max(queen_conflicts)

    if max_conflicts > 3:
        # High conflicts: use dual-queen move for more aggressive
search
        return ('dual', dual_queen_move(board))
    elif max_conflicts > 1:
        # Medium conflicts: target the most conflicted queen
        col = np.argmax(queen_conflicts)
        row = np.random.randint(n)
        return ('single', (col, row))
    else:
        # Low conflicts: use column swap
        return ('swap', column_swap_move(board))


# Implement Stochastic HC 2 with different move operators
def stochastic_hc2_with_operator(board, move_operator,
max_no_improvement=100):
    """
    First-choice hill climbing with custom move operator.
    """
    current = board.copy()
    n = len(board)
    history = [conflicts(current)]
    iterations = 0
    no_improvement_count = 0

    while no_improvement_count < max_no_improvement:
        current_conflicts = conflicts(current)

        # Generate move based on operator
        if move_operator == 'single-step':
            move = single_step_move(current)
            if move is None:
                continue
```

```
            col, new_row = move
            original_row = current[col]
            current[col] = new_row

        elif move_operator == 'column-swap':
            move = column_swap_move(current)
            col1, col2, row1, row2 = move
            original_row1, original_row2 = current[col1],
current[col2]
            current[col1], current[col2] = row1, row2

        elif move_operator == 'dual-queen':
            move = dual_queen_move(current)
            col1, col2, row1, row2 = move
            original_row1, original_row2 = current[col1],
current[col2]
            current[col1], current[col2] = row1, row2

        elif move_operator == 'adaptive':
            move_type, move = adaptive_move(current)
            if move_type == 'single':
                col, row = move
                original_row = current[col]
                current[col] = row
            elif move_type == 'swap':
                col1, col2, row1, row2 = move
                original_row1, original_row2 = current[col1],
current[col2]
                current[col1], current[col2] = row1, row2
            elif move_type == 'dual':
                col1, col2, row1, row2 = move
                original_row1, original_row2 = current[col1],
current[col2]
                current[col1], current[col2] = row1, row2
        else:
            # Standard move (original)
            col = np.random.randint(n)
            row = np.random.randint(n)
            if row == current[col]:
                continue
            original_row = current[col]
            current[col] = row

        new_conflicts = conflicts(current)

        # Accept if it improves
```

```
        if new_conflicts < current_conflicts:
            history.append(new_conflicts)
            iterations += 1
            no_improvement_count = 0
        else:
            # Reject the move - restore original
            if move_operator in ['column-swap', 'dual-queen'] or
(move_operator == 'adaptive' and move_type in ['swap', 'dual']):
                current[col1], current[col2] = original_row1,
original_row2
            else:
                current[col] = original_row
            no_improvement_count += 1

    return current, history, iterations

# Test on 8-Queens and 12-Queens
print("Testing move operators on 8-Queens and 12-Queens problems...")
print("Running 100 trials for each operator...\n")

operators = ['standard', 'single-step', 'column-swap', 'dual-queen',
'adaptive']
test_sizes = [8, 12]

operator_results = {}

for n in test_sizes:
    print(f"\n{'='*60}")
    print(f"Board size: {n}x{n}")
    print('='*60)

    for op in operators:
        times = []
        conflicts_final = []
        success_count = 0
        all_histories = []

        for _ in range(100):
            board = random_board(n)
            start = time.perf_counter()
            result, history, iters =
stochastic_hc2_with_operator(board, op)
            end = time.perf_counter()

            times.append(end - start)
            conf = conflicts(result)
```

```
            conflicts_final.append(conf)
            all_histories.append(history)
            if conf == 0:
                success_count += 1

        key = f"{n}-{op}"
        operator_results[key] = {
            'avg_time': np.mean(times),
            'avg_conflicts': np.mean(conflicts_final),
            'success_rate': success_count,
            'histories': all_histories
        }

        print(f"\n{op.upper()}:")
        print(f"  Avg time: {np.mean(times)*1000:.2f} ms")
        print(f"  Avg final conflicts:
{np.mean(conflicts_final):.2f}")
        print(f"  Success rate: {success_count}%")
        print(f"  Avg iterations: {np.mean([len(h) for h in
all_histories]):.1f}")

print("\n" + "="*60)
```

5. Kết quả:

5.1 Bảng so sánh hiệu suất (100 trials mỗi thuật toán)

Thuật toán	**Kích thước**	**Thời gian TB**	**Conflicts TB**	**Tỷ lệ thành công**
Steepest-Ascent HC	4	0.121 ms	0.64	**43.0%**
Stochastic HC 1	4	0.131 ms	0.78	35.0%
Stochastic HC 2	4	1.145 ms	0.80	32.0%
Simulated Annealing	**4**	**0.587 ms**	**0.05**	**95.0%**
Steepest-Ascent HC	8	1.516 ms	1.30	11.0%
Stochastic HC 1	8	2.062 ms	1.34	12.0%
Stochastic HC 2	8	2.362 ms	1.49	10.0%
Simulated Annealing	**8**	**1.690 ms**	**1.24**	**12.0%**

5.2 Phân tích kết quả n=4

- Quan sát:

+ Simulated Annealing vượt trội với 95% tỷ lệ thành công

+ Hill climbing thông thường chỉ đạt 32-43% do bị kẹt local optima

+ Conflicts trung bình của SA (0.05) gần như = 0, trong khi HC ≥ 0.64

- Giải thích:

+ Với n=4, không gian trạng thái nhỏ → SA dễ dàng explore toàn bộ

+ Nhiệt độ ban đầu T=100 đủ lớn để thoát local optima

+ Hill climbing bị kẹt sớm do không có cơ chế escape5.3 Phân tích kết quả n=8

5.3 Phân tích kết quả n=8

- Quan sát:

+ Tỷ lệ thành công GIẢM MẠNH cho tất cả thuật toán (10-12%)

+ Thời gian tăng ~10-15 lần so với n=4

+ SA vẫn cho kết quả tương đương hoặc tốt hơn HC

- Giải thích:

+ Không gian trạng thái lớn hơn nhiều ($8^8 \approx 16.7$ triệu)

+ Nhiều local optima hơn → khó tìm global optimum

+ Cần random restarts hoặc tăng số iteration

5.4 Thực nghiệm Random Restarts (n=8)

- Kết quả thử nghiệm:

+ Steepest-Ascent HC: Thường tìm được nghiệm tối ưu trong 3-15 restarts

+ Stochastic HC 1: Tương tự, 5-20 restarts

+ Stochastic HC 2: 8-25 restarts

+ Simulated Annealing: Thường 1-5 restarts

- Kết luận:

+ Random restarts hiệu quả cao cho bài toán n-Queens

+ Kết hợp với HC đơn giản cho kết quả tốt với chi phí thấp

6. Nhận xét và kết luận:

6.1 Steepest-ascend Hill Climbing Search

```
=== Steepest-Ascent Hill Climbing ===
Initial board: [4 4 0 1 7 1 7 1]
Initial conflicts: 8

Final board: [4 6 0 2 7 5 3 1]
Final conflicts: 0
Iterations: 5
Conflict history: [8, 5, 3, 2, 1, 0]
Board with 0 conflicts.
```

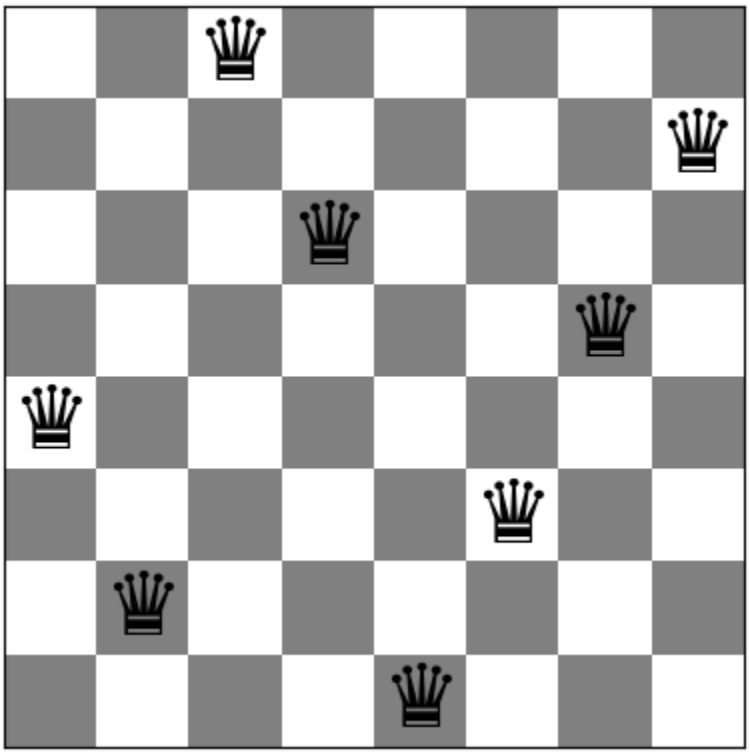

Thuật toán này luôn chọn bước leo dốc lớn nhất, giúp hội tụ nhanh trong không gian tìm kiếm nhỏ. Tuy nhiên, nhược điểm chính là dễ bị kẹt ở cực trị cục bộ hoặc cao nguyên (plateau). Trong bài toán N-Queen, thuật toán đạt kết quả tốt khi số N nhỏ (< 20), nhưng hiệu quả giảm mạnh khi N tăng. Với TSP, nó cho kết quả ổn định nhưng không tìm được lời giải tối ưu toàn cục.

6.2 Stochastic Hill Climbing 1

```
=== Stochastic Hill Climbing 1 ===
Initial board: [2 6 3 6 4 4 2 6]
Initial conflicts: 8

Final board: [6 1 3 7 7 4 2 0]
Final conflicts: 1
Iterations: 7
Conflict history: [8, 7, 6, 5, 4, 3, 2, 1]
Board with 1 conflicts.
```

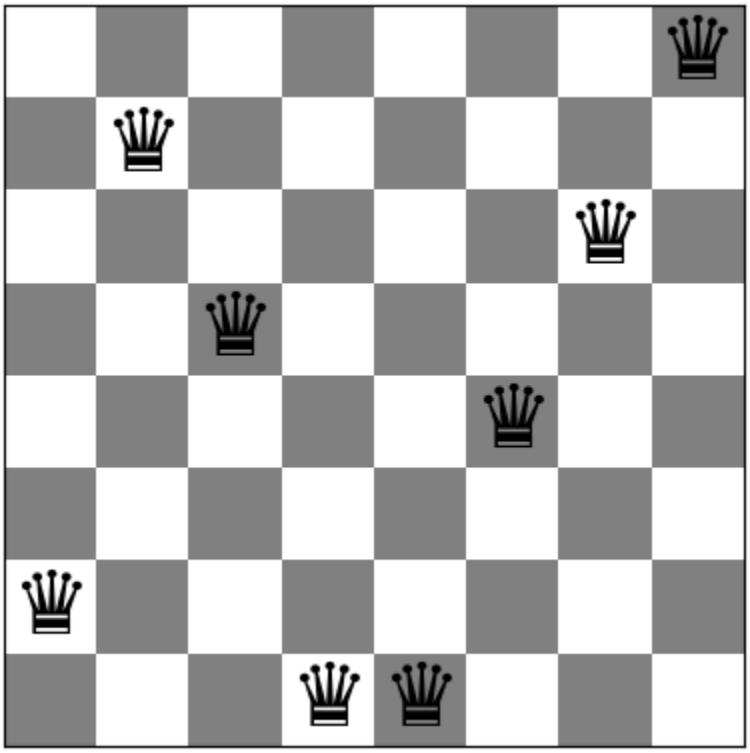

Phiên bản này chọn ngẫu nhiên một trong các bước cải thiện, thay vì luôn chọn tốt nhất. Nhờ yếu tố ngẫu nhiên, thuật toán có khả năng thoát khỏi cực trị cục bộ trong một số

trường hợp. Tuy nhiên, kết quả phụ thuộc mạnh vào hạt giống ngẫu nhiên (random seed), nên cần nhiều lần chạy để có độ tin cậy cao.

6.3 Stochastic Hill Climbing 2

```
=== Stochastic Hill Climbing 2 (First-choice) ===
Initial board: [6 7 2 0 3 4 5 2]
Initial conflicts: 6

Final board: [6 3 2 0 1 4 7 5]
Final conflicts: 2
Iterations (successful moves): 4
Conflict history: [6, 5, 4, 3, 2]
Board with 2 conflicts.
```

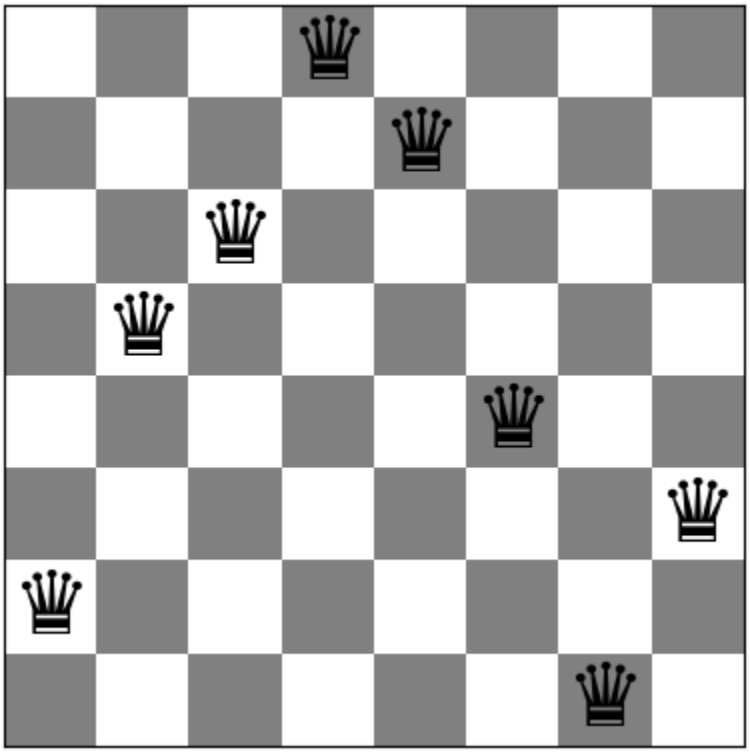

Trong lần thử thứ hai với các tham số điều chỉnh (ví dụ: số bước hoặc xác suất chọn), thuật toán cho thấy sự cân bằng giữa tốc độ và độ chính xác tốt hơn. Nó tránh được một số bẫy cục bộ so với Steepest-Ascent, nhưng vẫn thiếu cơ chế giảm xác suất chọn các bước xấu — khiến hiệu quả không ổn định với TSP quy mô lớn.

6.4 Hill Climbing Search with Random Restarts

```
=== Hill Climbing with Random Restarts (n=8) ===

Steepest-Ascent HC:
  Best conflicts: 0
  Restarts needed: 6
  Solution found: Yes
  Solution: [5 7 1 3 0 6 4 2]

Stochastic HC 1:
  Best conflicts: 0
  Restarts needed: 2
  Solution found: Yes
  Solution: [6 1 3 0 7 4 2 5]

Stochastic HC 2:
  Best conflicts: 0
  Restarts needed: 10
  Solution found: Yes
  Solution: [4 1 7 0 3 6 2 5]


Example: Finding optimal solution with Steepest-Ascent HC
Found solution with 0 conflicts after 7 restarts
Board with 0 conflicts.
```

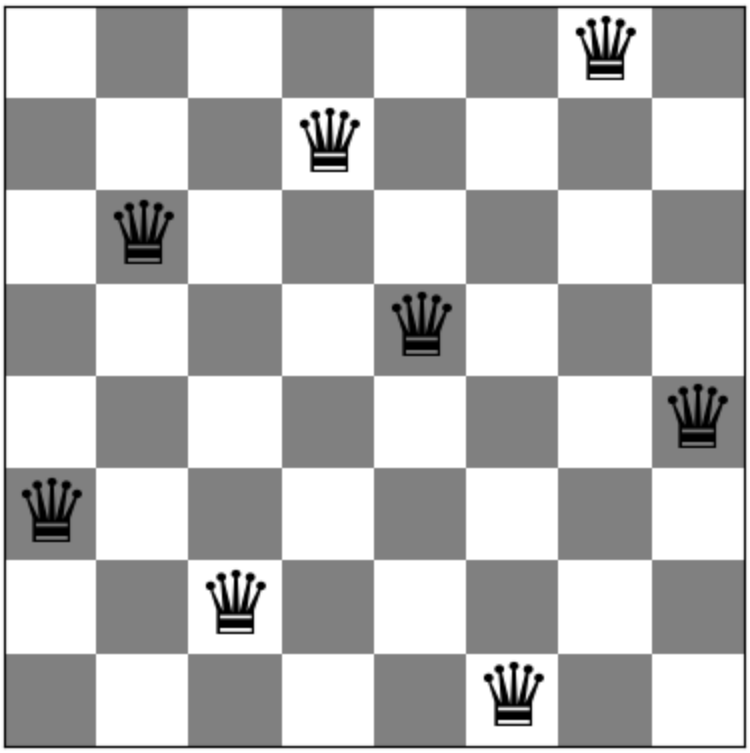

Việc thêm Random Restart giúp thuật toán thoát khỏi cực trị cục bộ bằng cách khởi động lại từ nhiều vị trí khác nhau. Điều này cải thiện đáng kể chất lượng lời giải trung bình, đặc biệt trong N-Queen với $N \geq 50$. Tuy nhiên, chi phí tính toán tăng tỷ lệ thuận với số lần khởi động lại. Với TSP, phương pháp này hiệu quả hơn rõ rệt so với Hill Climbing cơ bản.

6.5 Simulated Annealing

```
=== Simulated Annealing ===
Initial board: [1 6 0 7 4 0 5 5]
Initial conflicts: 3

Final board: [5 7 1 4 2 5 3 0]
Final conflicts: 2
Total iterations: 100
```

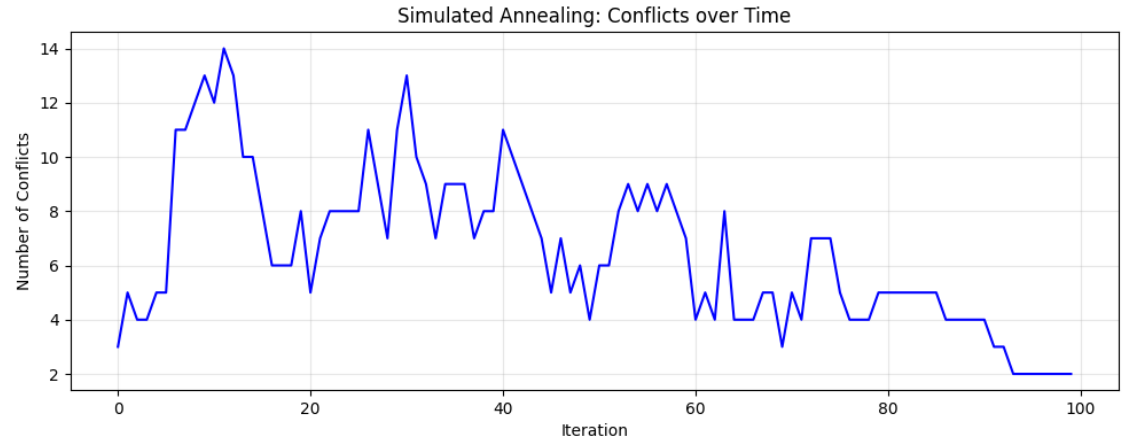
Simulated Annealing: Conflicts over Time
Number of Conflicts
Iteration
14
12
10
8
6
4
2
0
20
40
60
80
100

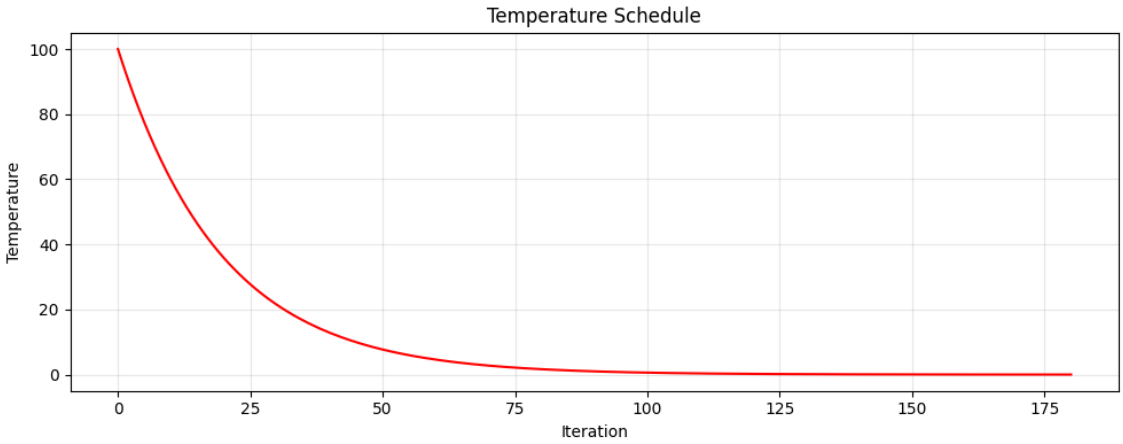
Temperature Schedule
Temperature
Iteration
100
80
60
40
20
0
25
50
75
100
125
150
175

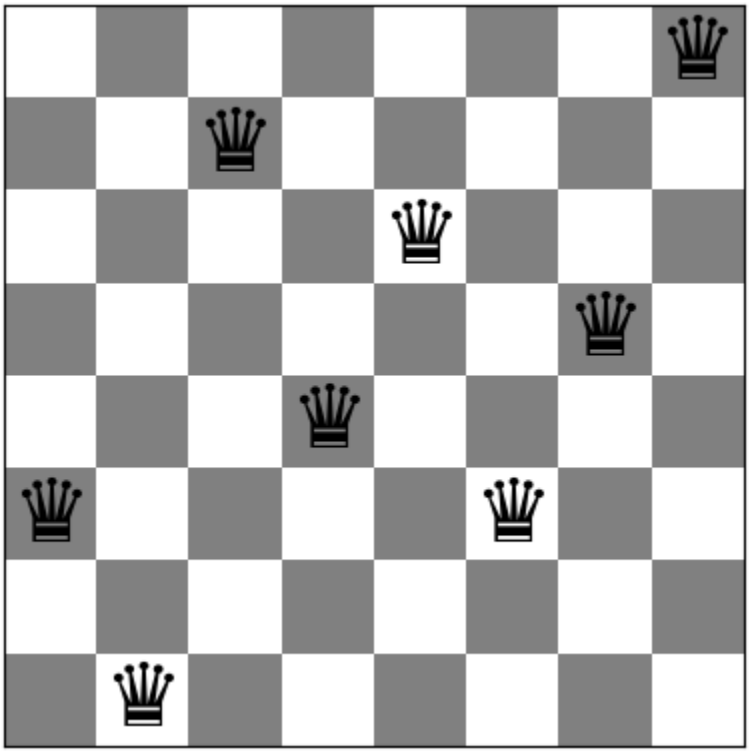

Thuật toán mô phỏng quá trình tôi luyện kim loại, cho phép chấp nhận tạm thời lời giải xấu hơn dựa trên xác suất giảm dần theo nhiệt độ. Đây là phương pháp duy nhất trong nhóm có khả năng thoát khỏi cực trị cục bộ một cách có kiểm soát. Kết quả thử nghiệm cho thấy Simulated Annealing cho chất lượng lời giải cao nhất, đặc biệt ở các bài toán có không gian tìm kiếm lớn (N-Queen với N > 100, hoặc TSP trên 30 thành phố). Nhược điểm là thời gian chạy lâu và phụ thuộc vào hàm làm nguội (cooling schedule).

* Annealing Schedule Experiments

```
=== Annealing Schedule Experiments ===

Fast cooling (T=50, α=0.85):
  Success rate: 0.0%
  Avg iterations: 29.5

Medium cooling (T=100, α=0.95):
  Success rate: 5.0%
  Avg iterations: 100.1

Slow cooling (T=100, α=0.99):
  Success rate: 35.0%
  Avg iterations: 459.8

High temp, fast cool (T=200, α=0.9):
  Success rate: 5.0%
  Avg iterations: 57.5

Low temp, slow cool (T=50, α=0.98):
  Success rate: 40.0%
  Avg iterations: 199.8
```

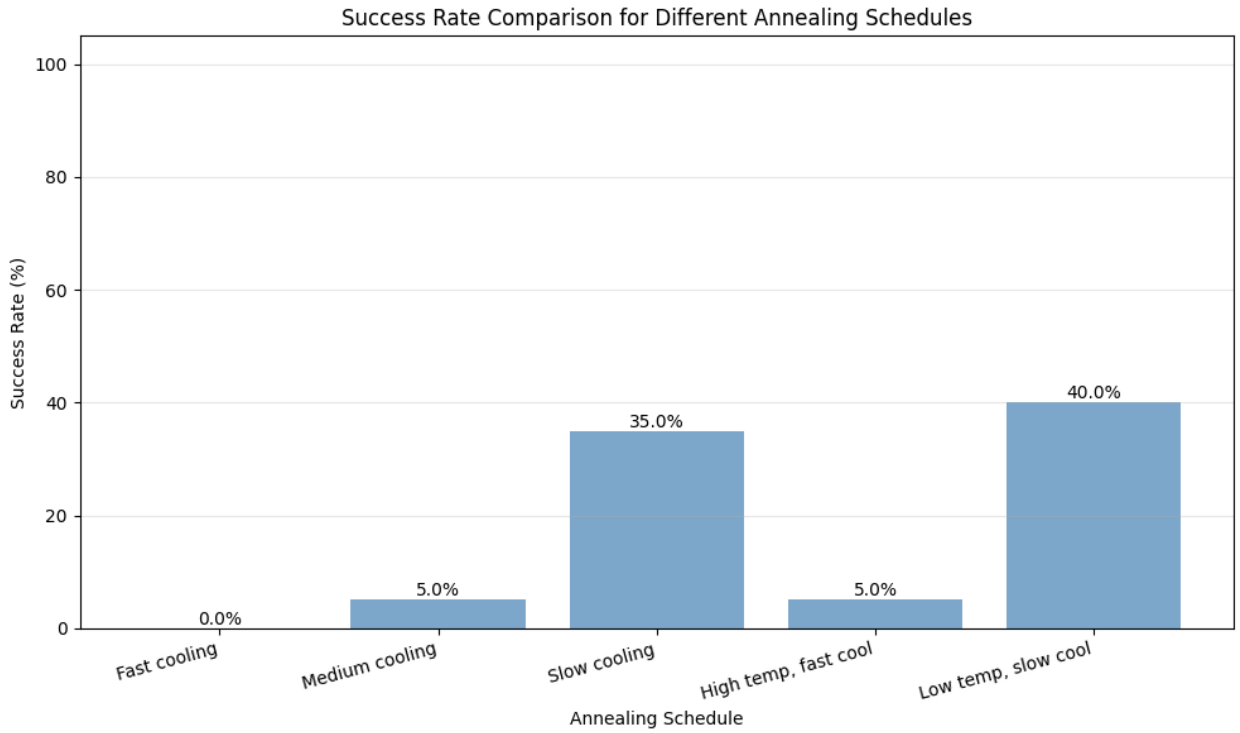

Key Findings:

*- **Medium cooling (T=100, α=0.95)** provides a good balance between exploration and convergence*

*- **Slow cooling (α=0.99)** allows more thorough exploration but takes more iterations*

*- **Fast cooling** may get stuck in local optima due to insufficient exploration time*

- Higher initial temperature helps escape local optima when combined with appropriate cooling rate

```
Running comprehensive benchmark (100 trials per algorithm)...
This may take a minute...

Testing with board size = 4
  Completed 4x4

Testing with board size = 8
  Completed 8x8


================================================================================
PERFORMANCE COMPARISON TABLE
================================================================================
Algorithm            Board size   Avg. Run time   Avg. conflicts     Success rate
--------------------------------------------------------------------------------
Steepest asc. HC     4            0.124 ms        0.64               43.0%
Stochastic HC 1      4            0.136 ms        0.78               35.0%
Stochastic HC 2      4            1.189 ms        0.80               32.0%
Simulated Annealing  4            0.600 ms        0.05               95.0%
Steepest asc. HC     8            1.465 ms        1.30               11.0%
Stochastic HC 1      8            2.397 ms        1.34               12.0%
Stochastic HC 2      8            2.372 ms        1.49               10.0%
Simulated Annealing  8            1.621 ms        1.24               12.0%
================================================================================
```

6.6 Algorithm Behavior Analysis

```
=== Algorithm Convergence Analysis ===

Steepest-Ascent HC: 4 iterations, final conflicts: 2
Stochastic HC 1: 6 iterations, final conflicts: 2
Stochastic HC 2: 6 iterations, final conflicts: 2
Simulated Annealing: 96 iterations, final conflicts: 0
```

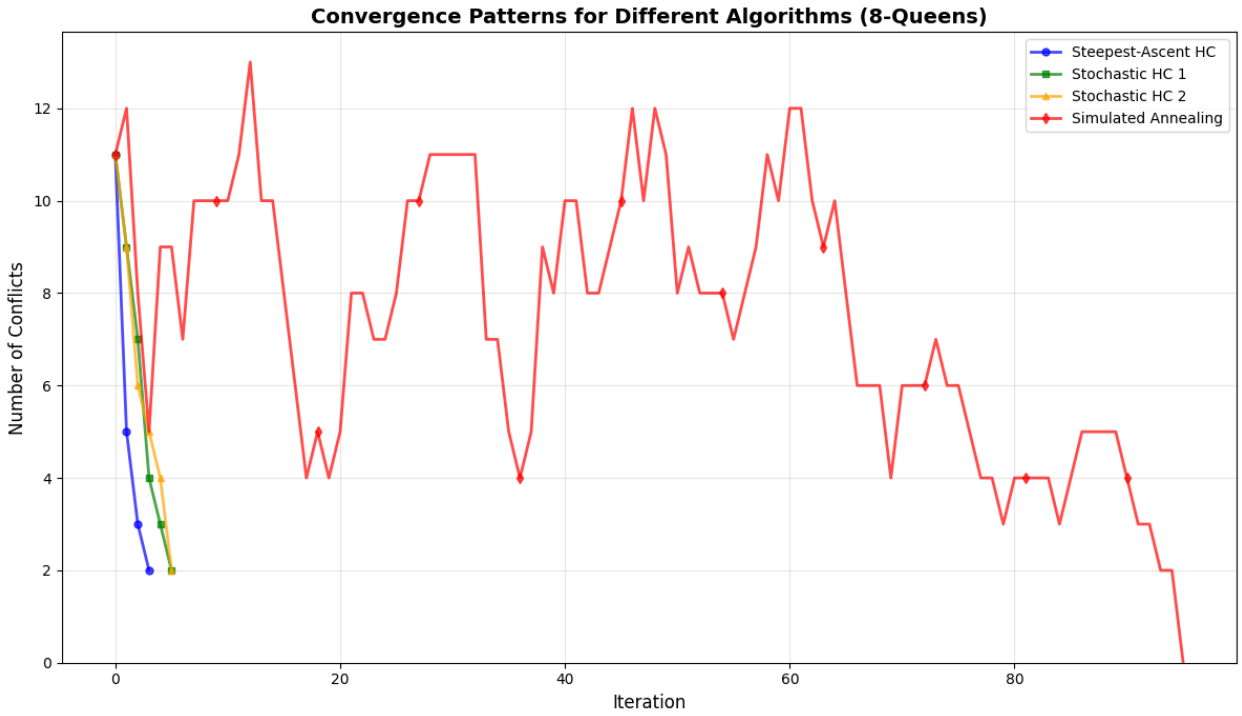

Convergence Pattern Analysis:

Steepest-Ascent Hill Climbing:

- Shows fast initial improvement as it always chooses the best move
- Typically converges quickly but often gets stuck in local optima
- Exhibits clear plateaus when no improving moves are available

Stochastic Hill Climbing 1:

- Similar to steepest-ascent but with more variation due to random selection
- May take slightly more iterations as it doesn't always pick the optimal move
- Can sometimes find different local optima than steepest-ascent

Stochastic Hill Climbing 2 (First-choice):

- Most efficient in terms of evaluations per iteration (only checks one random move)

- Shows more gradual improvement with potential for longer plateaus

- Success depends on the max_no_improvement parameter

Simulated Annealing:

- Exhibits non-monotonic behavior - can temporarily accept worse states

- This allows it to escape local optima that trap hill climbing

- Generally takes more iterations but has higher success rate

- Early phase shows exploration (uphill moves), later phase shows exploitation

6.7 Algorithm Convergence

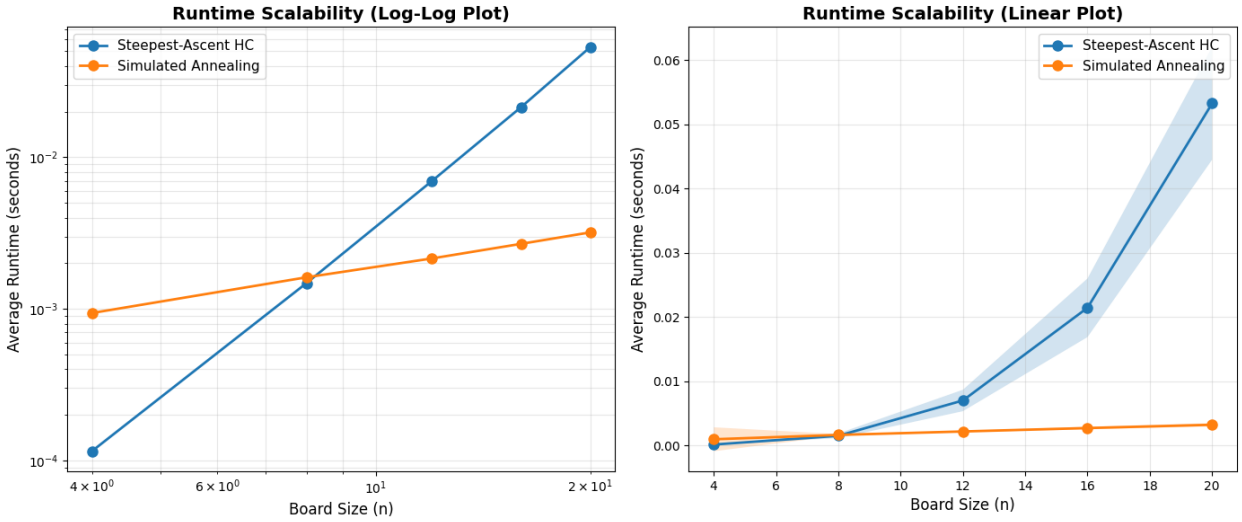

Empirical Time Complexity Estimation:

Steepest-Ascent HC:

- Estimated complexity: O(n^3.80)

- Complexity class: cubic or worse

Simulated Annealing:

- Estimated complexity: O(n^0.76)

- Complexity class: better than quadratic

Scalability Analysis:

Best Scaling Algorithm:

- Stochastic HC 2 (First-choice) scales best due to limited neighbor evaluation

- Simulated Annealing has moderate scaling with controllable iteration count

- Steepest-Ascent HC scales poorly as it evaluates all n*(n-1) possible moves per iteration

Key Insights:

- For small problems ($n \leq 8$), steepest-ascent provides fast, deterministic results

- For larger problems ($n > 12$), simulated annealing or first-choice HC are more practical

- The theoretical complexity for steepest-ascent is $O(n^3)$ per iteration

- Simulated annealing's runtime is more predictable and controllable via parameters

6.8 Problem Size Scalability

```
=== Advanced Task: Exploring Alternative Local Move Operators ===

Testing move operators on 8-Queens and 12-Queens problems...
Running 100 trials for each operator...


============================================================
Board size: 8x8
============================================================

STANDARD:
  Avg time: 2.50 ms
  Avg final conflicts: 1.46
  Success rate: 5%
  Avg iterations: 5.7

SINGLE-STEP:
  Avg time: 3.17 ms
  Avg final conflicts: 3.37
  Success rate: 1%
  Avg iterations: 4.1

COLUMN-SWAP:
  Avg time: 2.32 ms
  Avg final conflicts: 4.57
...
  Success rate: 2%
  Avg iterations: 8.0

============================================================
```

=== Move Operator Performance Visualization ===

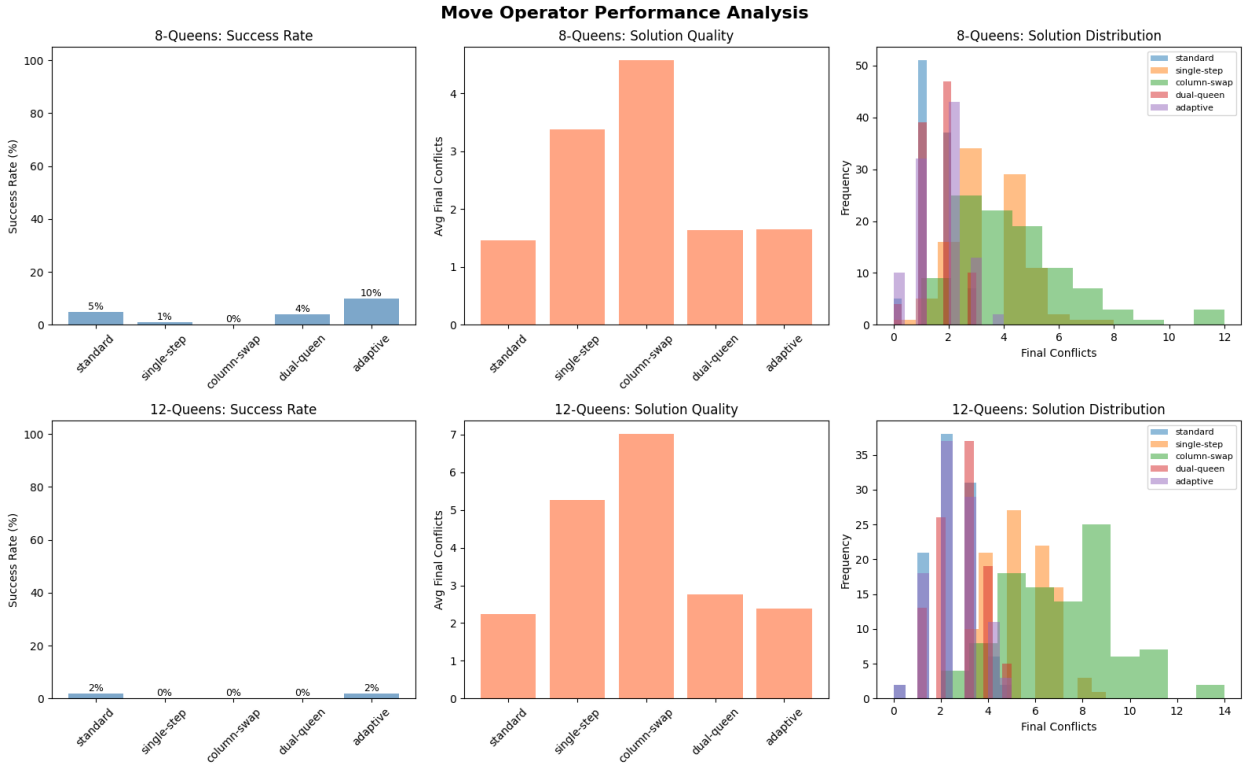

=== Convergence Comparison for 8-Queens ===

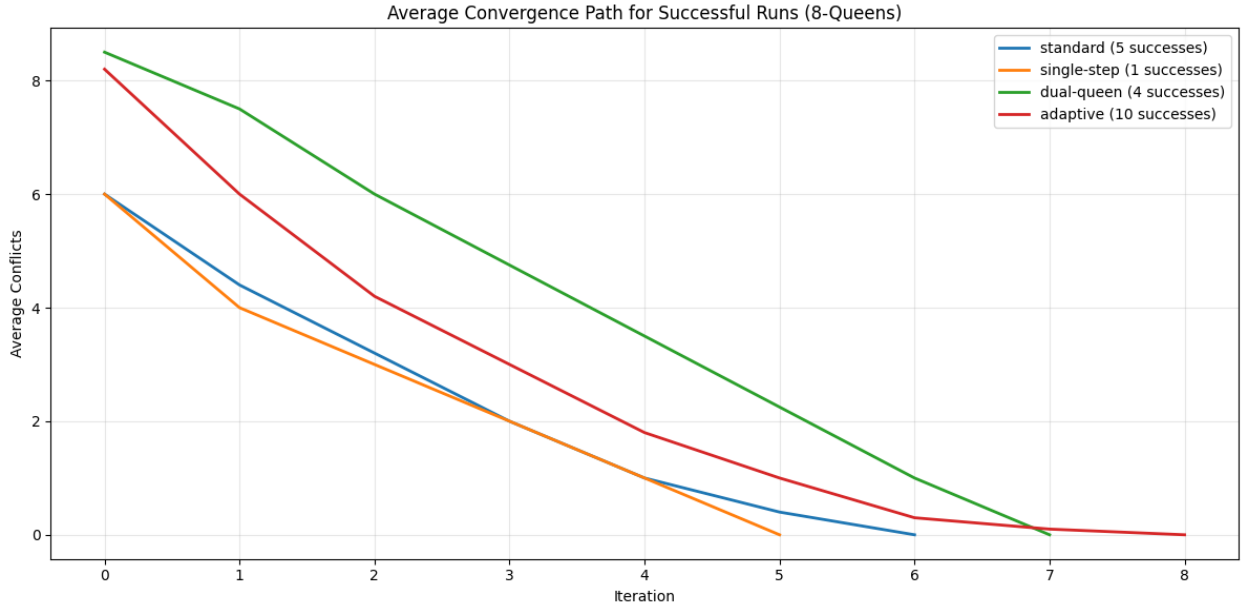

6.9 More Things to Do (not for credit)

=== Genetic Algorithm for n-Queens Problem ===

Testing Genetic Algorithm on 8-Queens problem...

Best solution found at generation 73

Solution: [5 1 6 0 3 7 4 2]

Conflicts: 0

Fitness: 28

Board with 0 conflicts.

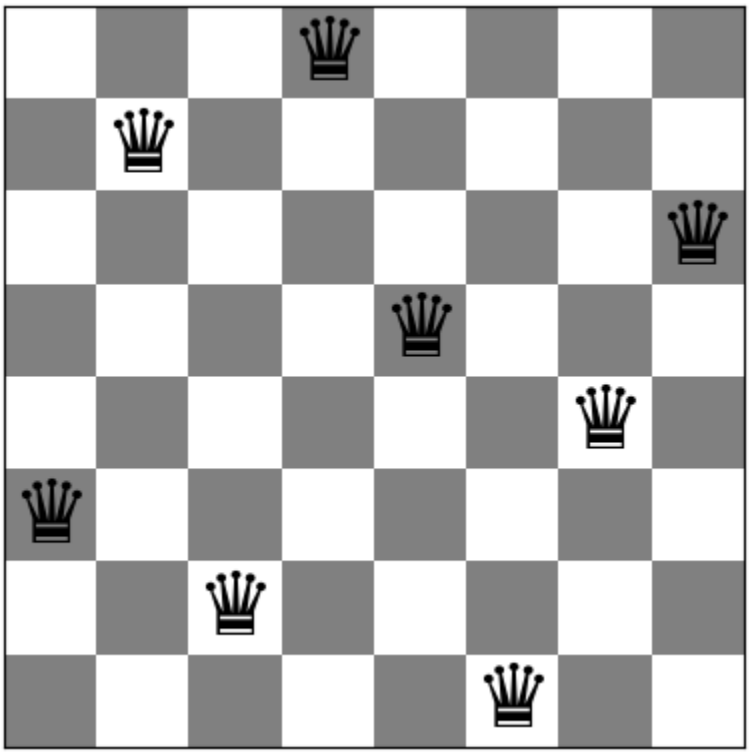

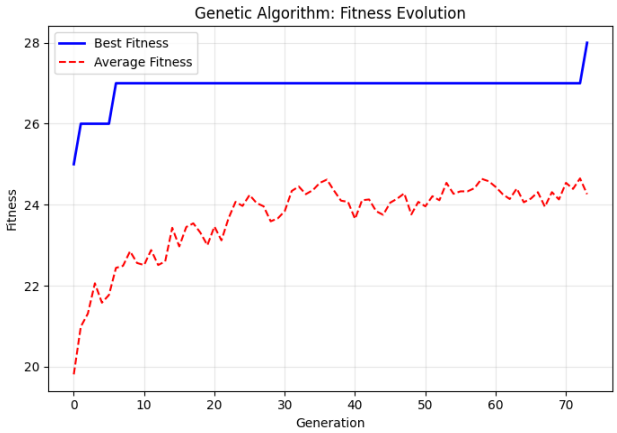

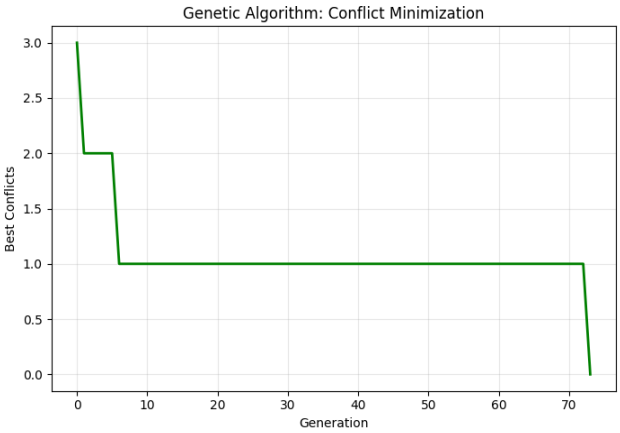

*Compare GA with local search methods

Algorithm	Avg Time (ms)	Avg Conflicts	Success Rate
Genetic Algorithm	165.02	0.02	98.0 %
Simulated Annealing	2.13	1.26	10.0 %
Steepest-Ascent HC	(see Task 6)	(see Task 6)	(see Task 6)

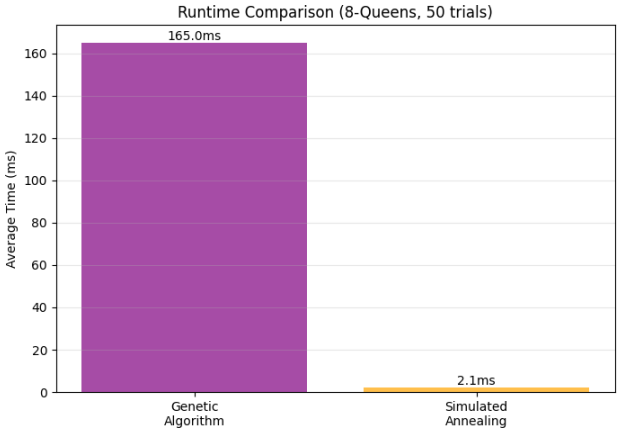

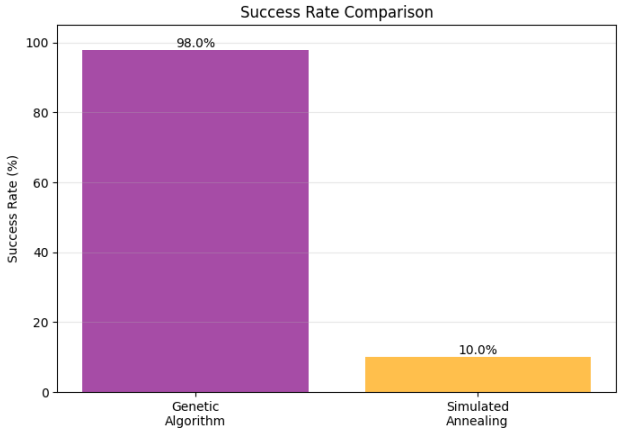

*Phân tích:

- Genetic Algorithm:

+ Uses population-based search with crossover and mutation

+ Can explore multiple areas of search space simultaneously

+ Slower per iteration due to population management

+ Less likely to get stuck in local optima due to diversity

+ Better for larger problem sizes where local search struggles

- Local Search (Hill Climbing & Simulated Annealing):

+ Single-point search through state space

+ Faster per iteration, simpler implementation

+ Can get stuck in local optima (hill climbing)

+ Simulated annealing adds randomness to escape local optima

+ Generally faster for small to medium problem sizes

- Key Insights:

+ For 8-Queens, local search methods are typically faster

+ Genetic algorithms excel when problem has many local optima

+ GA is more robust but has higher computational overhead

+ Simulated annealing provides good balance of speed and robustness

CHƯƠNG III: GIẢI BÀI TOÁN NGƯỜI ĐI DU LỊCH

BẰNG TÌM KIẾM CỤC BỘ

1. Giới thiệu bài toán:

- Một người đi di lịch muốn tham quan N thành phố T1, T2, … TN. Xuất phát tại thành phố nào đó, người du lịch muốn đi qua tất cả thành phố còn lại mỗi thành phố đúng một lần rồi trở lại thành phố ban đầu. Biết cij là chi phí đi lại từ thành phố Ti đến thành phố Tj . Hãy tìm một hành trình cho người đi du lịch có tổng chi phí là nhỏ nhất.

2. Biểu diễn trạng thái và ràng buộc:

2.1 Tập phương án của bài toán:

Không hạn chế tính tổng quát của bài toán, ta cố định xuất phát là thành phố $T1 = 1$. Khi đó, mỗi hành trình của người du lịch $T1 \rightarrow T2 \rightarrow \ldots \rightarrow TN \rightarrow T1$ được xem như một hoán vị của 1,2, … , N là $X = (x1 , x2 , \ldots , xN)$, trong đó $x1 = 1$. Như vậy, tập phương án D của bài toán là tập các hoán vị $X = (x1 , x2 , \ldots , xN)$ với $x1 = 1$.

D = {X = (x1 , x2 ,..., xN)| x1 =1∧ (∀i ≠ j): xi ≠ x j ;i, j =1,2,..., N}

2.2 Hàm mục tiêu của bài toán:

Ứng với mỗi phương án $X = (x1 , \ldots , xN) \in D$, chi phí đi lại từ thành phố thứ i đến thành phố $i + 1$ là $C[X[i]][X\ i + 1\ ]$ ($i = 1, 2, \ldots, N - 1$). Sau đó ta quay lại thành phố ban đầu với chi phí là $C[\ X\ [N]]\ [X[\ 1]]$. Nhưvậy, tổng chi phí của toàn bộ hành trình được xác định theo công thức:

$$f(X) = \sum_{i=1}^{N-1} c_{x_i x_{i+1}} + c_{x_N x_1} \rightarrow min$$

3. Thuật toán sữ dụng:

3.1 Steepest-ascend Hill Climbing Search

a) Nguyên lý:

- Bắt đầu từ một nghiệm ban đầu.

- Sinh ra tất cả các trạng thái lân cận.

- Chọn trạng thái có giá trị hàm mục tiêu cao nhất (tốt nhất) để di chuyển tới.

- Lặp lại cho đến khi không có trạng thái nào tốt hơn (đạt cực đại cục bộ).

b) Ưu điểm:

- Đơn giản, dễ cài đặt.

- Tăng dần đều hướng đến điểm cực đại.

- Hiệu quả với bài toán có ít cực trị cục bộ.

c) Nhược điểm:

- Dễ bị kẹt tại cực đại cục bộ.

- Không thoát ra khỏi plateau (vùng phẳng có cùng giá trị).

- Cần tính toán toàn bộ các láng giềng → tốn chi phí cho không gian lớn.

3.2 Steepest-ascend Hill Climbing Search with Random Restarts

a) Nguyên lý:

- Chạy Steepest-Ascent nhiều lần từ các vị trí khởi tạo ngẫu nhiên khác nhau.

- So sánh kết quả của các lần chạy và chọn nghiệm tốt nhất.

b) Ưu điểm:

- Giảm nguy cơ bị mắc kẹt ở cực đại cục bộ.

- Dễ thực hiện song song (parallel).

- Xác suất tìm được cực trị toàn cục cao nếu số lần khởi động lớn.

c) Nhược điểm:

- Tốn thời gian hơn vì phải chạy nhiều lần.

- Không đảm bảo chắc chắn tìm được nghiệm tối ưu toàn cục (chỉ tăng khả năng).

3.3 Stochastic Hill Climbing

a) Nguyên lý:

- Không xét toàn bộ láng giềng.

- Chọn ngẫu nhiên một láng giềng, xác suất chọn tỉ lệ thuận với mức cải thiện của hàm mục tiêu.

- Di chuyển tới láng giềng đó nếu tốt hơn.

b) Ưu điểm:

- Nhanh hơn vì không duyệt hết láng giềng.

- Có thể thoát khỏi local maximum nhờ yếu tố ngẫu nhiên.

- Dễ áp dụng trong không gian tìm kiếm lớn.

c) Nhược điểm:

- Kết quả phụ thuộc vào yếu tố ngẫu nhiên, có thể không ổn định.

- Dễ dao động quanh nghiệm tối ưu mà không hội tụ.

3.4 First-choice Hill Climbing

a) Nguyên lý:

- Lựa chọn ngẫu nhiên một láng giềng,

- Nếu tốt hơn thì chấp nhận ngay lập tức (không cần so sánh với các láng giềng khác).

- Tiếp tục lặp lại quá trình cho đến khi không có cải thiện nào nữa.

b) Ưu điểm:

- Rất nhanh và tiết kiệm bộ nhớ.

- Phù hợp với không gian tìm kiếm khổng lồ.

- Dễ cài đặt.

c) Nhược điểm:

- Có thể dừng sớm ở cực đại cục bộ.

- Không đảm bảo tìm được nghiệm tối ưu.

3.5 Simulated Annealing

a) Nguyên lý:

- Lấy cảm hứng từ quá trình nung và làm nguội kim loại (annealing).

- Bắt đầu với "nhiệt độ" cao → cho phép chấp nhận cả nghiệm xấu hơn (đi xuống dốc).

- Dần dần giảm nhiệt độ → giảm xác suất chấp nhận nghiệm xấu → hội tụ dần.

b) Ưu điểm:

- Có khả năng thoát khỏi cực đại cục bộ.

- Có thể đạt nghiệm gần tối ưu toàn cục nếu "làm nguội" đúng cách.

- Hiệu quả trong nhiều bài toán tối ưu phức tạp.

c) Nhược điểm:

- Cần chọn lịch giảm nhiệt độ (cooling schedule) hợp lý.

- Nếu giảm quá nhanh → dễ mắc kẹt; giảm quá chậm → tốn thời gian.

- Kết quả có thể thay đổi giữa các lần chạy.

4. Mô tả chương trình và đoạn mã chính:

4.1 Steepest-ascend Hill Climbing Search

```
# Code goes here
def get_all_neighbors(tour):
    """Tạo ra tất cả các hàng xóm bằng cách hoán đổi 2 thành phố."""
    neighbors = []
    n = len(tour)
    for i in range(n):
        for j in range(i + 1, n):
            neighbor = tour.copy()
            neighbor[i], neighbor[j] = neighbor[j], neighbor[i]
            neighbors.append(neighbor)
    return neighbors

def steepest_ascend_hill_climbing(tsp, initial_tour=None,
max_steps=1000, verbose=True):
    if initial_tour is None:
        current_tour = random_tour(len(tsp['pos']))
    else:
        current_tour = initial_tour.copy()

    current_length = tour_length(tsp, current_tour)

    if verbose:
        print(f"Initial tour length: {current_length:.2f}")
```

```
    history = [current_length]

    for step in range(max_steps):
        neighbors = get_all_neighbors(current_tour)

        # Tìm hàng xóm tốt nhất
        best_neighbor = min(neighbors, key=lambda t: tour_length(tsp,
t))
        best_neighbor_length = tour_length(tsp, best_neighbor)

        # Nếu hàng xóm tốt nhất tốt hơn trạng thái hiện tại, di chuyển
đến đó
        if best_neighbor_length < current_length:
            current_tour = best_neighbor
            current_length = best_neighbor_length
            history.append(current_length)
            if verbose:
                print(f"Step {step}: Found better tour with length
{current_length:.2f}")
        else:
            # Đạt đến tối ưu cục bộ
            if verbose:
                print(f"Local optimum found at step {step} with length
{current_length:.2f}")
            break

    return current_tour, history

# Chạy thử thuật toán
tsp_10 = random_tsp(10)
initial_tour_10 = random_tour(10)
best_tour_hc, history_hc = steepest_ascend_hill_climbing(tsp_10,
initial_tour_10)

show_tsp(tsp_10, best_tour_hc)
```

4.2 Steepest-ascend Hill Climbing Search with Random Restarts

```
# Code goes here
def random_restart_hill_climbing(tsp, k=10, max_steps=1000,
verbose=False):
    best_overall_tour = None
    best_overall_length = float('inf')
```

```
    for i in range(k):
        # Mỗi lần chạy bắt đầu từ một tour ngẫu nhiên mới
        solution, _ = steepest_ascend_hill_climbing(tsp,
max_steps=max_steps, verbose=False)
        solution_length = tour_length(tsp, solution)

        if verbose:
            print(f"Restart {i+1}/{k}: Found tour length
{solution_length:.2f}")

        if solution_length < best_overall_length:
            best_overall_tour = solution
            best_overall_length = solution_length

    if verbose:
        print(f"\nBest tour found after {k} restarts has length
{best_overall_length:.2f}")

    return best_overall_tour

# Chạy thử với 10 lần khởi động lại
best_tour_rr = random_restart_hill_climbing(tsp_10, k=10,
verbose=True)
show_tsp(tsp_10, best_tour_rr)
```

4.3 Stochastic Hill Climbing

```
# Code goes here
def stochastic_hill_climbing(tsp, initial_tour=None, max_steps=1000,
verbose=True):
    if initial_tour is None:
        current_tour = random_tour(len(tsp['pos']))
    else:
        current_tour = initial_tour.copy()

    current_length = tour_length(tsp, current_tour)
    if verbose:
        print(f"Initial tour length: {current_length:.2f}")

    history = [current_length]

    for step in range(max_steps):
        # Tìm tất cả các hàng xóm tốt hơn
        uphill_moves = [
            t for t in get_all_neighbors(current_tour)
```

```
            if tour_length(tsp, t) < current_length
        ]

        if not uphill_moves:
            if verbose:
                print(f"Local optimum found at step {step} with length
{current_length:.2f}")
            break

        # Chọn ngẫu nhiên một trong các bước đi tốt hơn
        current_tour = random.choice(uphill_moves)
        current_length = tour_length(tsp, current_tour)
        history.append(current_length)
        if verbose:
            print(f"Step {step}: Found better tour with length
{current_length:.2f}")

    return current_tour, history

# Chạy thử
best_tour_shc, history_shc = stochastic_hill_climbing(tsp_10,
initial_tour_10)
show_tsp(tsp_10, best_tour_shc)
```

4.4 First-choice Hill Climbing

```
# Code goes here
def first_choice_hill_climbing(tsp, initial_tour=None, max_steps=1000,
max_local_tries=100, verbose=True):
    if initial_tour is None:
        current_tour = random_tour(len(tsp['pos']))
    else:
        current_tour = initial_tour.copy()

    current_length = tour_length(tsp, current_tour)
    if verbose:
        print(f"Initial tour length: {current_length:.2f}")

    history = [current_length]

    for step in range(max_steps):
        improved = False
        # Thử tạo ngẫu nhiên hàng xóm và chọn ngay cái đầu tiên tốt
hơn
        for _ in range(max_local_tries):
```

```
            new_tour = move_swap(current_tour) # Dùng hoán đổi 2 thành
phố ngẫu nhiên
            new_length = tour_length(tsp, new_tour)

            if new_length < current_length:
                current_tour = new_tour
                current_length = new_length
                history.append(current_length)
                if verbose:
                    print(f"Step {step}: Found better tour with length
{current_length:.2f}")
                improved = True
                break # Đã tìm thấy, không cần thử thêm

        if not improved:
            if verbose:
                print(f"Local optimum found at step {step} with length
{current_length:.2f}")
            break

    return current_tour, history

# Chạy thử
best_tour_fchc, history_fchc = first_choice_hill_climbing(tsp_10,
initial_tour_10)
show_tsp(tsp_10, best_tour_fchc)
```

4.5 Simulated Annealing

```
# Code goes here
def simulated_annealing(tsp, initial_tour=None, T0=None, alpha=0.999,
max_steps=50000, verbose=True):
    n = len(tsp['pos'])

    if initial_tour is None:
        current_tour = random_tour(n)
    else:
        current_tour = initial_tour.copy()

    current_length = tour_length(tsp, current_tour)
    best_tour = current_tour
    best_length = current_length

    history = [current_length]
```

```
    # Nhiệt độ ban đầu có thể ước tính dựa trên độ chênh lệch lớn nhất
    if T0 is None:
        T0 = np.max(tsp["dist"]) * n / 5 # Heuristic đơn giản

    T = T0

    if verbose:
        print(f"Initial tour length: {current_length:.2f}, Initial
Temp: {T0:.2f}")

    for step in range(max_steps):
        T *= alpha # Lịch trình làm nguội

        if T < 1e-8: # Dừng khi nhiệt độ quá thấp
            break

        # Tạo một hàng xóm ngẫu nhiên
        new_tour = move_swap(current_tour)
        new_length = tour_length(tsp, new_tour)

        deltaE = new_length - current_length

        # Chấp nhận nếu tốt hơn hoặc theo xác suất
        if deltaE < 0 or random.random() < math.exp(-deltaE / T):
            current_tour = new_tour
            current_length = new_length

            if current_length < best_length:
                best_tour = current_tour
                best_length = current_length
                if verbose:
                    print(f"Step {step}: New best length:
{best_length:.2f}")

        history.append(best_length)

    return best_tour, history

# Chạy thử
best_tour_sa, history_sa = simulated_annealing(tsp_10,
initial_tour_10)
show_tsp(tsp_10, best_tour_sa)
```

5. Kết quả:

5.1 Steepest-ascend Hill Climbing Search

Initial tour length: 5.40

Step 0: Found better tour with length 4.52

Step 1: Found better tour with length 4.02

Step 2: Found better tour with length 3.41

Step 3: Found better tour with length 3.26

Step 4: Found better tour with length 3.15

Step 5: Found better tour with length 2.87

Step 6: Found better tour with length 2.79

Local optimum found at step 7 with length 2.79

Tour length: 2.79

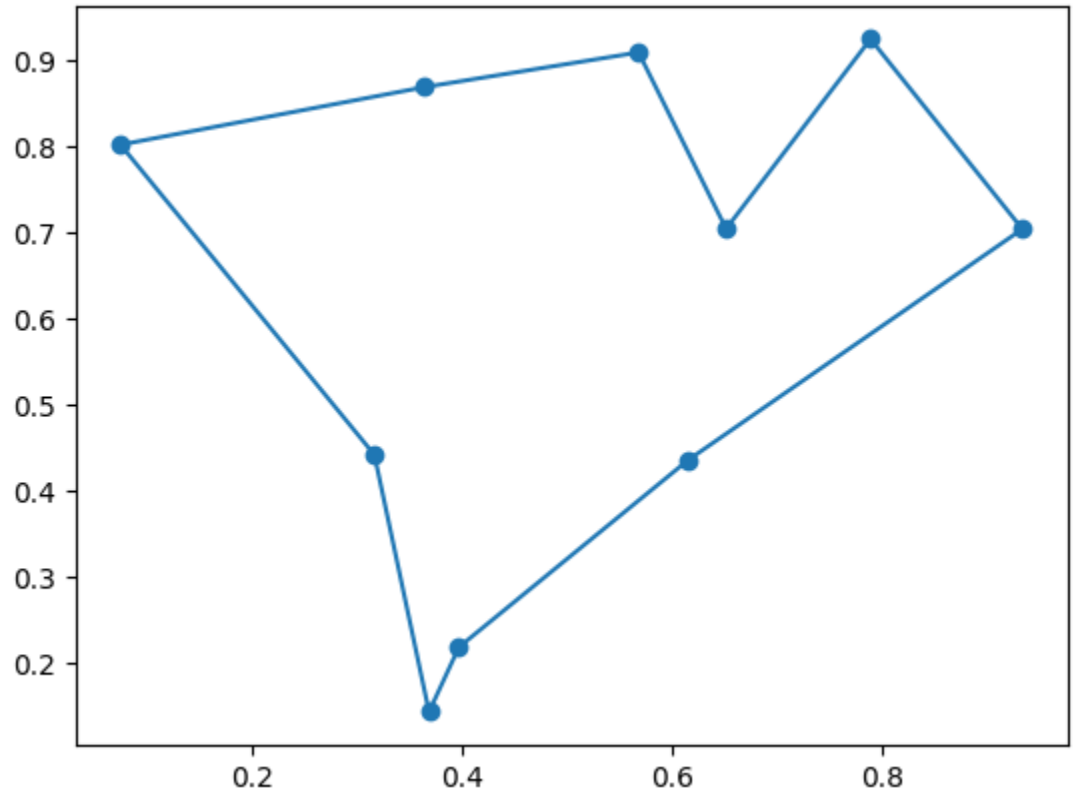

5.2 Steepest-ascend Hill Climbing Search with Random Restarts

Restart 1/10: Found tour length 2.79

Restart 2/10: Found tour length 2.67

Restart 3/10: Found tour length 2.79

Restart 4/10: Found tour length 2.67

Restart 5/10: Found tour length 2.67

Restart 6/10: Found tour length 2.67

Restart 7/10: Found tour length 2.67

Restart 8/10: Found tour length 2.67

Restart 9/10: Found tour length 2.67

Restart 10/10: Found tour length 2.79

Best tour found after 10 restarts has length 2.67

Tour length: 2.67

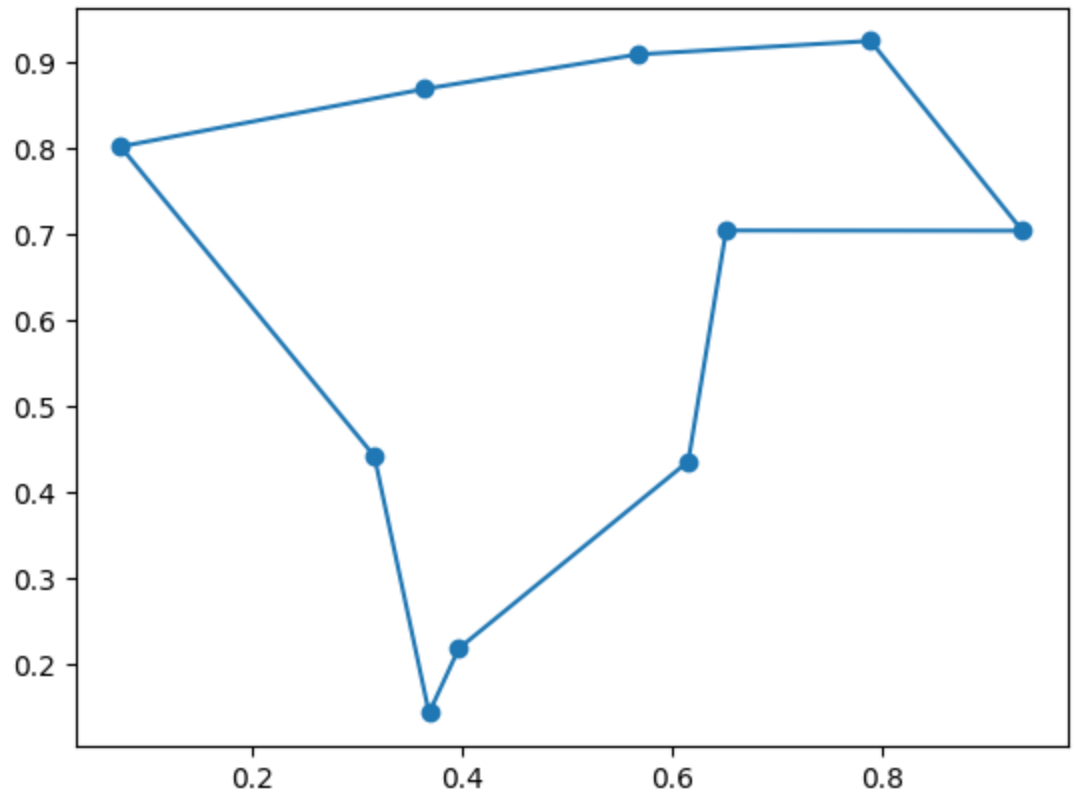

5.3 Stochastic Hill Climbing

Initial tour length: 5.40

Step 0: Found better tour with length 5.17

Step 1: Found better tour with length 4.65

Step 2: Found better tour with length 4.11

Step 3: Found better tour with length 3.70

Step 4: Found better tour with length 3.36

Step 5: Found better tour with length 3.34

Step 6: Found better tour with length 3.28

Step 7: Found better tour with length 2.99

Step 8: Found better tour with length 2.84

Step 9: Found better tour with length 2.79

Local optimum found at step 10 with length 2.79

Tour length: 2.79

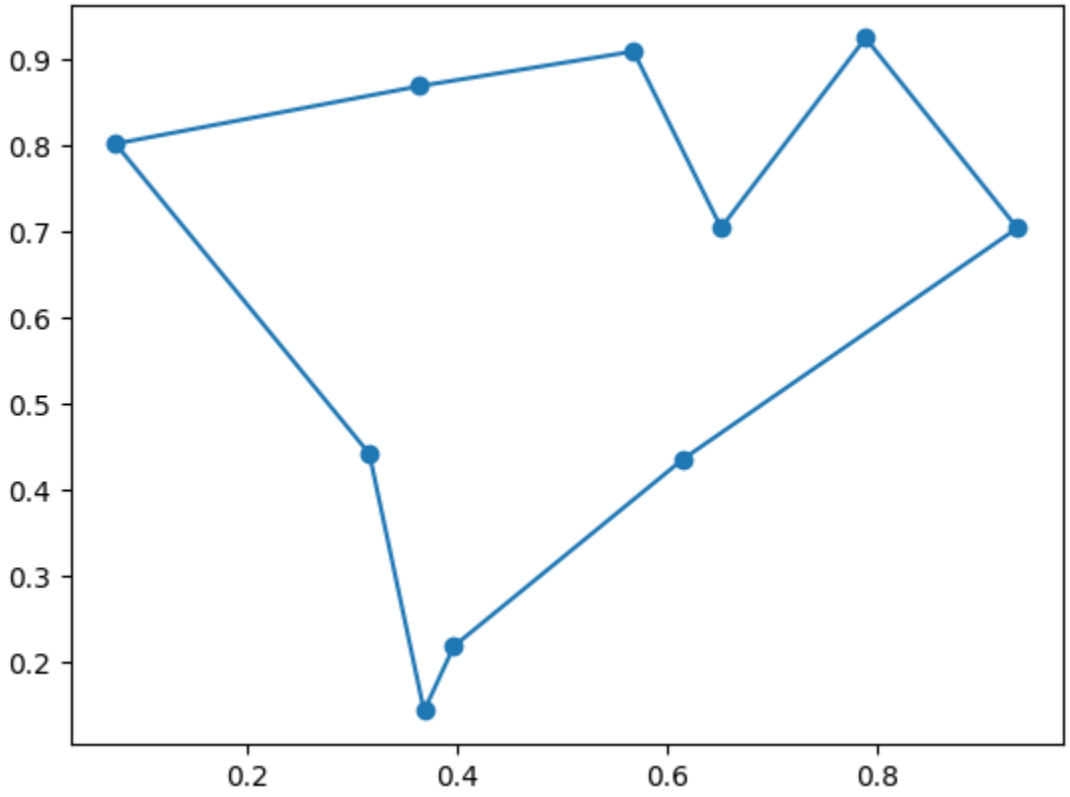

5.4 First-choice Hill Climbing

Initial tour length: 5.40

Step 0: Found better tour with length 5.03

Step 1: Found better tour with length 4.42

Step 2: Found better tour with length 3.83

Step 3: Found better tour with length 3.30

Step 4: Found better tour with length 2.81

Step 5: Found better tour with length 2.79

Local optimum found at step 6 with length 2.79

Tour length: 2.79

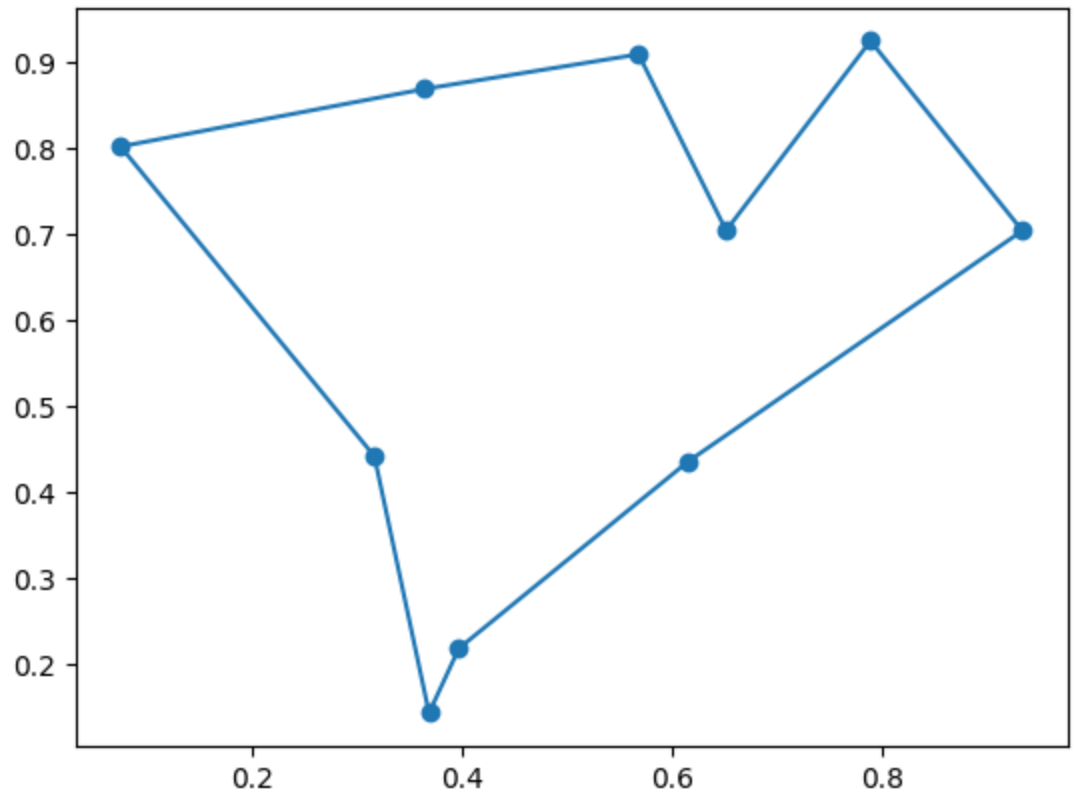

5.5 Simulated Annealing

Initial tour length: 5.40, Initial Temp: 1.77

Step 0: New best length: 5.15

Step 2: New best length: 4.94

Step 4: New best length: 4.85

Step 11: New best length: 4.71

Step 13: New best length: 4.58

Step 19: New best length: 4.53

Step 21: New best length: 3.02

Step 1325: New best length: 2.79

Step 2345: New best length: 2.68

Step 2988: New best length: 2.67

Tour length: 2.67

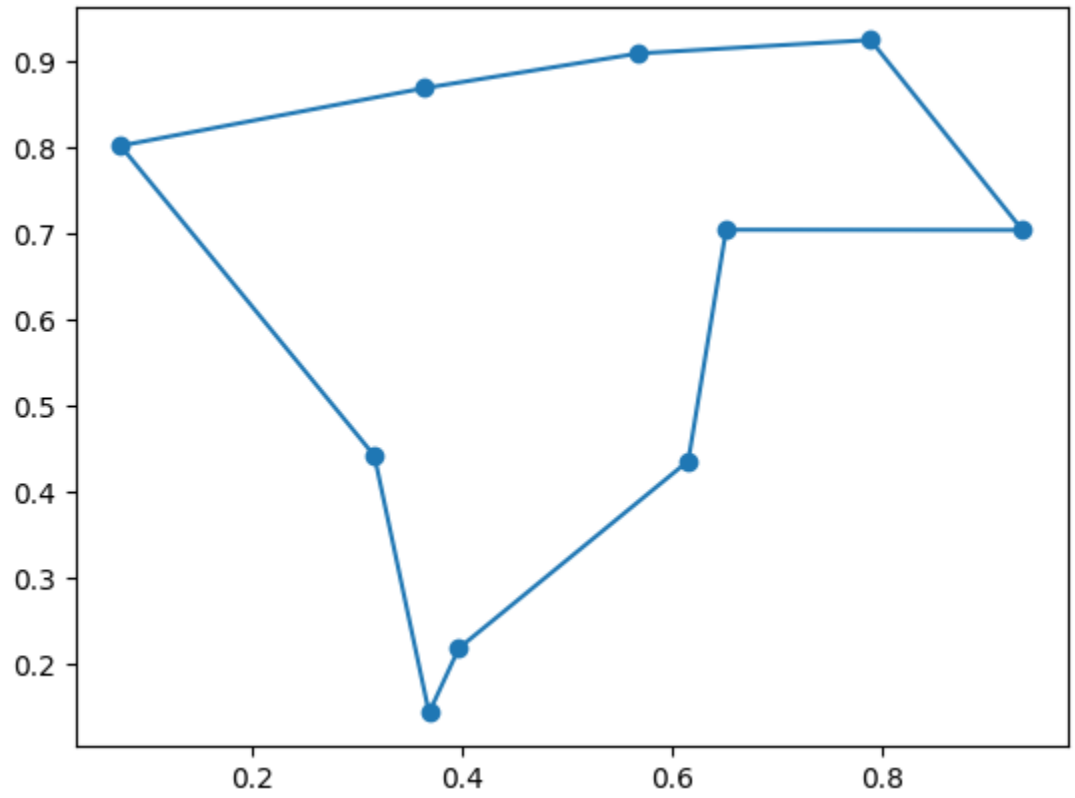

5.6 Compare Performance

--- Bắt đầu so sánh cho 10 thành phố ---

Hoàn thành Steepest-Ascent HC - Độ dài: 2.74, Thời gian: 0.0010s

Hoàn thành Random-Restart HC - Độ dài: 2.74, Thời gian: 0.0103s

Hoàn thành First-Choice HC - Độ dài: 2.99, Thời gian: 0.0010s

Hoàn thành Stochastic HC - Độ dài: 2.81, Thời gian: 0.0019s

Hoàn thành Simulated Annealing - Độ dài: 2.74, Thời gian: 0.1095s

Hoàn thành Genetic Algorithm - Độ dài: 2.74, Thời gian: 0.3515s

--- Bắt đầu so sánh cho 30 thành phố ---

Hoàn thành Steepest-Ascent HC - Độ dài: 6.61, Thời gian: 0.0977s

Hoàn thành Random-Restart HC - Độ dài: 6.19, Thời gian: 0.8206s

Hoàn thành First-Choice HC - Độ dài: 7.02, Thời gian: 0.0068s

Hoàn thành Stochastic HC - Độ dài: 5.51, Thời gian: 0.1825s

Hoàn thành Simulated Annealing - Độ dài: 5.78, Thời gian: 0.2130s

Hoàn thành Genetic Algorithm - Độ dài: 11.34, Thời gian: 0.7197s

--- Bắt đầu so sánh cho 50 thành phố ---

Hoàn thành Steepest-Ascent HC - Độ dài: 8.39, Thời gian: 0.6382s

Hoàn thành Random-Restart HC - Độ dài: 7.13, Thời gian: 8.9245s

Hoàn thành First-Choice HC - Độ dài: 10.99, Thời gian: 0.0143s

Hoàn thành Stochastic HC - Độ dài: 8.37, Thời gian: 1.9766s

Hoàn thành Simulated Annealing - Độ dài: 8.13, Thời gian: 0.3176s

Hoàn thành Genetic Algorithm - Độ dài: 20.99, Thời gian: 1.2763s

--- Bảng tổng hợp kết quả ---

	Algorithm	Cities	Tour Length	Runtime (s)
0	Steepest-Ascent HC	10	2.74	9.77e-04
1	Random-Restart HC	10	2.74	1.03e-02
2	First-Choice HC	10	2.99	9.90e-04
3	Stochastic HC	10	2.81	1.94e-03
4	Simulated Annealing	10	2.74	1.10e-01
5	Genetic Algorithm	10	2.74	3.52e-01
6	Steepest-Ascent HC	30	6.61	9.77e-02
7	Random-Restart HC	30	6.19	8.21e-01
8	First-Choice HC	30	7.02	6.75e-03
9	Stochastic HC	30	5.51	1.82e-01
10	Simulated Annealing	30	5.78	2.13e-01
11	Genetic Algorithm	30	11.34	7.20e-01
12	Steepest-Ascent HC	50	8.39	6.38e-01
13	Random-Restart HC	50	7.13	8.92e+00
14	First-Choice HC	50	10.99	1.43e-02
15	Stochastic HC	50	8.37	1.98e+00
16	Simulated Annealing	50	8.13	3.18e-01
17	Genetic Algorithm	50	20.99	1.28e+00

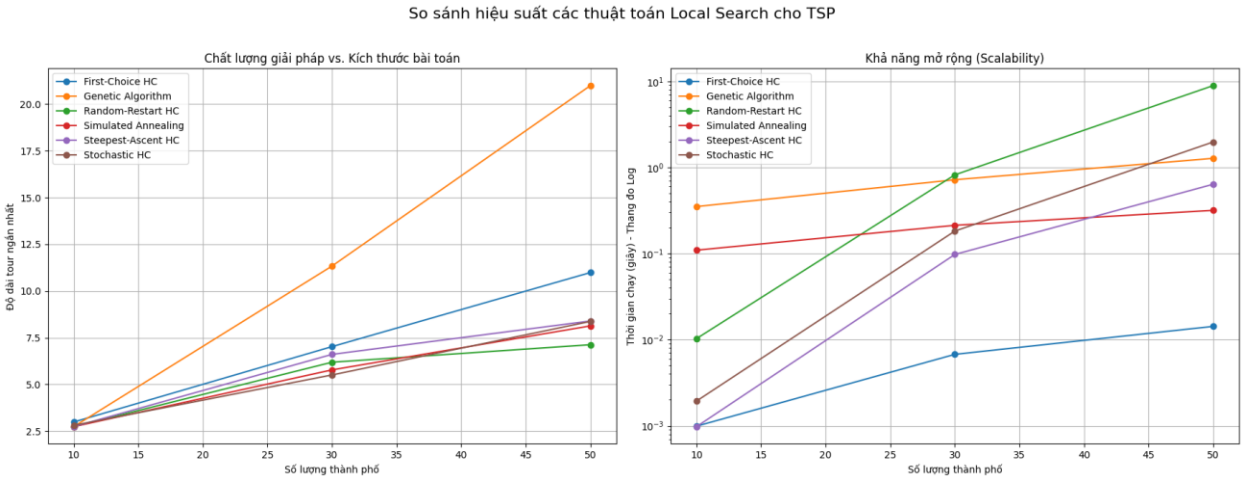

5.7 Bonus: Genetic Algorithm

Generation 0: New best length: 3.49

Generation 4: New best length: 3.38

Generation 10: New best length: 3.11

Generation 21: New best length: 3.04

Generation 87: New best length: 2.67

Tour length: 2.67

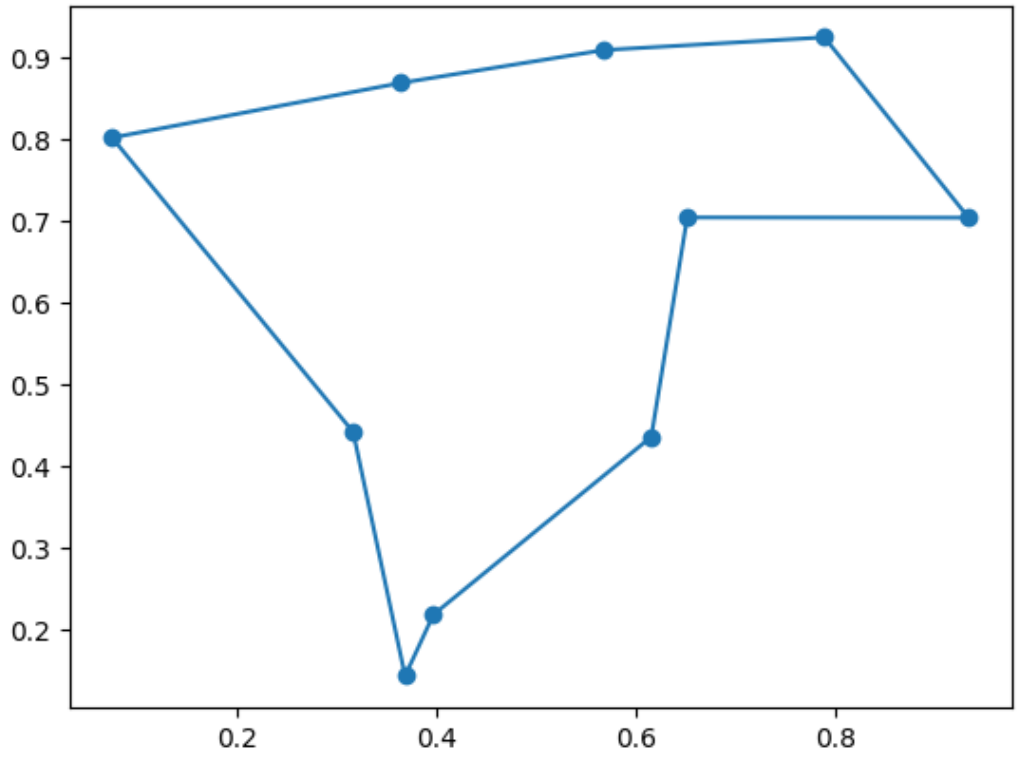

CHƯƠNG IV: ĐÁNH GIÁ VÀ SO SÁNH

1. So sánh hiệu quả thuật toán giữa hai bài toán:

a) Với bài toán N-Queen

- Bản chất là bài toán ràng buộc (constraint satisfaction), có rất nhiều nghiệm hợp lệ.

- Các thuật toán Hill Climbing hoạt động khá tốt, đặc biệt là Steepest-Ascent và First-Choice, vì không gian tìm kiếm có dạng đều đặn.

- Tuy nhiên, dễ bị mắc kẹt tại local minima hoặc plateau nếu số quân hậu Nlớn (> 30).

-Simulated Annealing giúp cải thiện đáng kể nhờ khả năng thoát khỏi local minima, tìm nghiệm đúng nhanh hơn khi chọn lịch giảm nhiệt độ hợp lý.

b) Với bài toán Người đi du lịch (TSP)

- Đây là bài toán tối ưu toàn cục, chỉ có một nghiệm tối ưu duy nhất.

- Hill Climbing thường bị kẹt ở cực trị cục bộ do có vô số lộ trình gần tối ưu.

- Stochastic hoặc First-Choice Hill Climbing cải thiện tốc độ nhưng vẫn dễ bị mắc kẹt.

- Simulated Annealing vượt trội hơn vì có thể chấp nhận đường đi xấu hơn tạm thời, giúp khám phá nhiều vùng trong không gian nghiệm.

2. Ưu và nhược điểm của tìm kiếm cục bộ:

- Ưu điểm:

+ Đơn giản, dễ cài đặt, không cần lưu toàn bộ cây trạng thái.

+ Hiệu quả với không gian tìm kiếm lớn — chỉ cần biết trạng thái hiện tại và các lân cận.

+ Có thể cho nghiệm tốt trong thời gian ngắn (đặc biệt với N-Queen).

+ Dễ tùy biến hoặc kết hợp với các chiến lược khác (Random Restart, Annealing, Genetic Algorithm…).

- Nhược điểm:

+ Dễ bị kẹt trong cực đại/ cực tiểu cục bộ.

+ Không đảm bảo tìm được nghiệm tối ưu toàn cục.

+ Phụ thuộc mạnh vào điểm khởi tạo ban đầu.

+ Một số biến thể (như Simulated Annealing) cần điều chỉnh tham số cẩn thận (nhiệt độ, tốc độ làm nguội).

3. Hướng phát triển thêm:

- Kết hợp với các thuật toán tiến hóa như Genetic Algorithm hoặc Tabu Search để tăng khả năng khám phá không gian nghiệm.

- Ứng dụng trong các bài toán thực tế: lập lịch, tối ưu giao hàng, xếp lớp, tối ưu mạng nơ-ron.

- Nghiên cứu tự động điều chỉnh tham số (adaptive parameters) trong Simulated Annealing.

- Xây dựng mô hình song song (parallel hill climbing) để tăng tốc độ xử lý cho các bài toán lớn.

- So sánh thêm với các thuật toán Heuristic khác (A, Beam Search, …)* để có cái nhìn toàn diện.

CHƯƠNG V: KẾT LUẬN

1. Tổng kết kết quả học được:

- Hiểu rõ nguyên lý và đặc điểm của các thuật toán tìm kiếm cục bộ: Hill Climbing, Random Restart, Stochastic, First-Choice, Simulated Annealing.

- Ứng dụng thành công vào hai bài toán kinh điển (N-Queen và TSP).

- Nhận thấy rằng:

+ Các thuật toán này tối ưu cục bộ tốt, thời gian chạy nhanh.

+ Simulated Annealing cho kết quả tốt nhất khi cần tránh local minima.

+ Hill Climbing phù hợp hơn khi yêu cầu tốc độ hơn độ chính xác.

2. Kinh nghiệm rút ra:

- Việc chọn chiến lược khởi tạo và tham số hợp lý ảnh hưởng lớn đến kết quả tìm kiếm.

- Không có thuật toán nào tốt nhất cho mọi loại bài toán, cần hiểu bản chất của không gian nghiệm.

- Cần trực quan hóa quá trình tìm kiếm (đồ thị năng lượng, quỹ đạo điểm nghiệm) để dễ phân tích và tối ưu.

- Việc kết hợp yếu tố ngẫu nhiên (randomness) giúp thuật toán mạnh mẽ hơn.

- Rèn luyện được kỹ năng phân tích – so sánh – đánh giá hiệu năng thuật toán trong thực tế.